


華南理工大學

South China University of Technology

大模型智能体基础与应用

# 第一讲：大模型简介

陈亦乐
计算机科学与工程学院
chenyile@scut.edu.cn

2026年9月3日

# 课程介绍

- 课程目标：
  - 了解大模型基本原理及推理优化和端云协同技术
  - 了解智能体基本原理以及组成构件设计
  - 了解垂域相关智能体模型与知识
  - 了解在企业中的智能体落地前沿方案

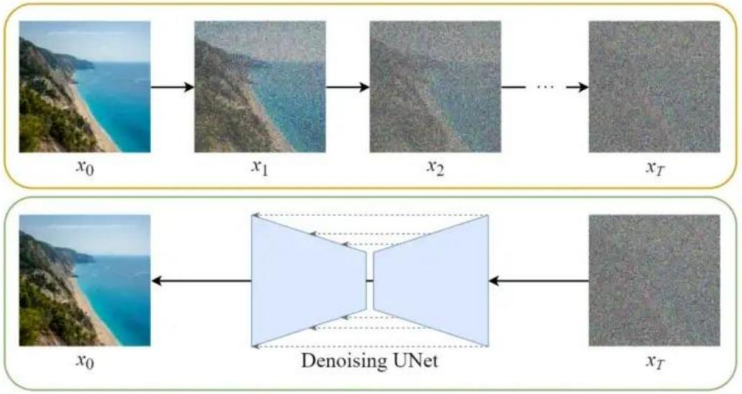
- 成绩构成：
  - 平时成绩（30%）
  - 小组作业（70%）

# 课程介绍

- 小组作业（70%）：
  - 课程报告（30%）+课堂展示（25%）+个人贡献（15%）
  - 4人一组，第2周周五23:59分前确定好分组和选题，第10周上课前提交课程报告
  - 围绕教育、校园服务、企业办公、个人助理等真实需求，设计一个大模型智能体应用，需体现完整应用逻辑和智能体各模块的设计和工程思维。
  - 报告中需明确记录具体分工和每个人工作所占比例（例如40%，40%，10%，10%），展示时会进行针对性提问验证真实性。

# 人工智能的世界

IMAGENET







豆包 - 字节跳动旗下 AI 智能助手

Using Codex with your ChatGPT plan

Claude Code by Anthropic | AI Codin

DeepSeek - 探索未至之境

Google Gemini

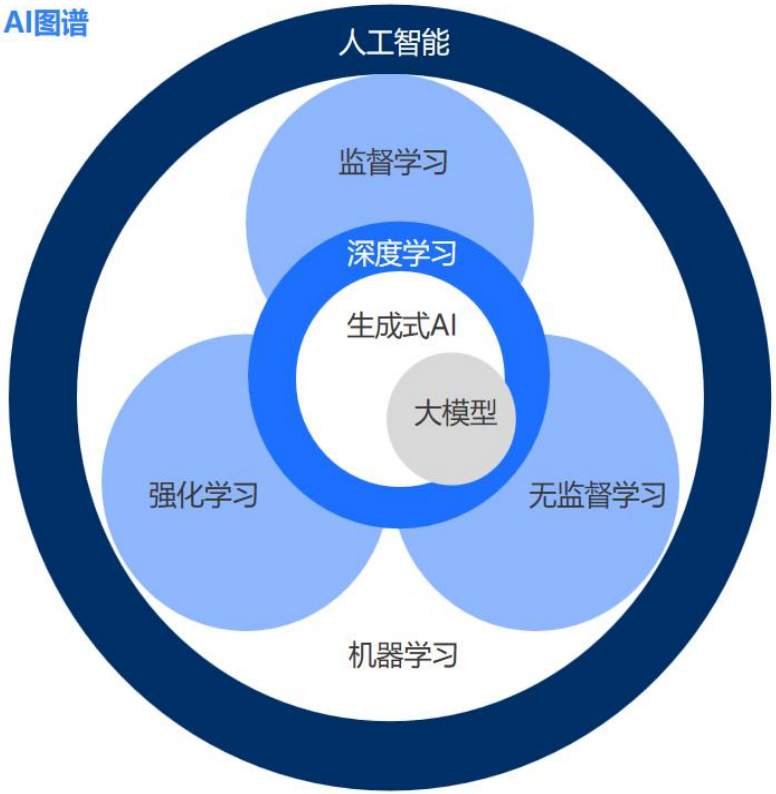
Kimi AI 官网 - K3 上线，专为智能体

千问-阿里 AI 助手

Grok - 在线 AI 聊天

# 人工智能？机器学习？深度学习？生成式AI？

- **人工智能**（AI）模拟人类智能行为，如图像识别、语言理解和决策制定，已经深刻融入日常生活。（顶层目标）
- **机器学习**（Machine learning）是让机器自动从数据中找到规律学习函数，例如分类。（实现手段）
  - 监督学习：有标准答案。
  - 无监督学习：在杂乱数据中找规律。
  - 强化学习：像训练小狗一样，通过反馈（奖励/惩罚）学习策略。




**举例：**

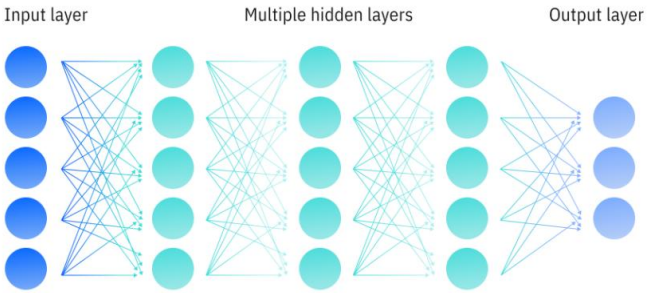
输入：



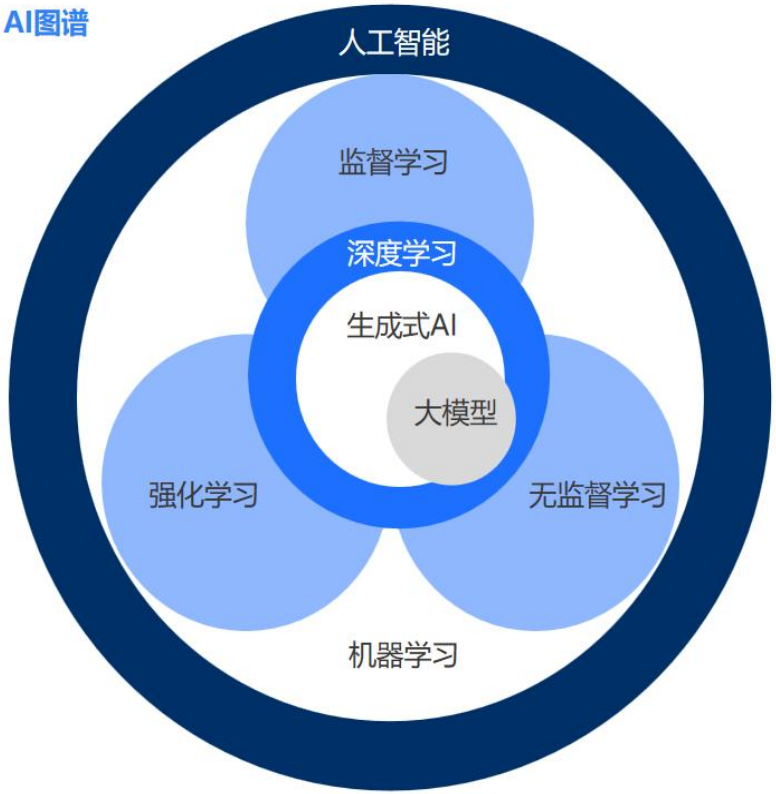
**输出：** 狗　猫　狗　猫

# 人工智能？机器学习？深度学习？生成式AI？

- **人工智能（AI）**模拟人类智能行为，如图像识别、语言理解和决策制定，已经深刻融入日常生活。（顶层目标）
- **深度学习（Deep learning）**属于模仿人脑神经元的一种机器学习技术，用神经网络堆叠层数（更厉害的手段）




AI图谱




- AI技术从早期缓慢发展到2012年深度学习的突破，实现了飞速进步，如今已广泛应用于**健康医疗、交通、安防、金融**等多个领域。

# 人工智能？机器学习？深度学习？生成式AI？

- 生成式AI（Generative AI）在目前多以深度学习达成，可产生**复杂**有结构的物件

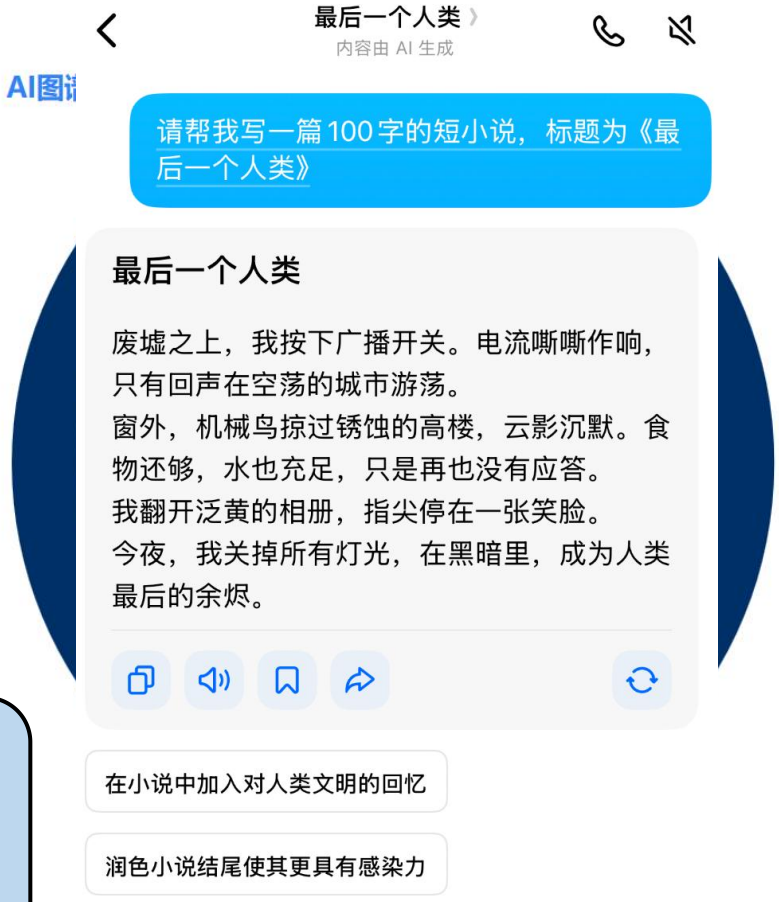
**文章**
**由文字所构成**

**图像**
**由像素所构成**

**语音**
**由取样点构成**



**生成一篇100字的小说，题目为《最后一个人类》**




**假设中文常用字为1000:**

$1000 \times 1000 \times \ldots = 1000^{100} = 10^{300}$

**宇宙中的原子总数估计为$10^{80}$**

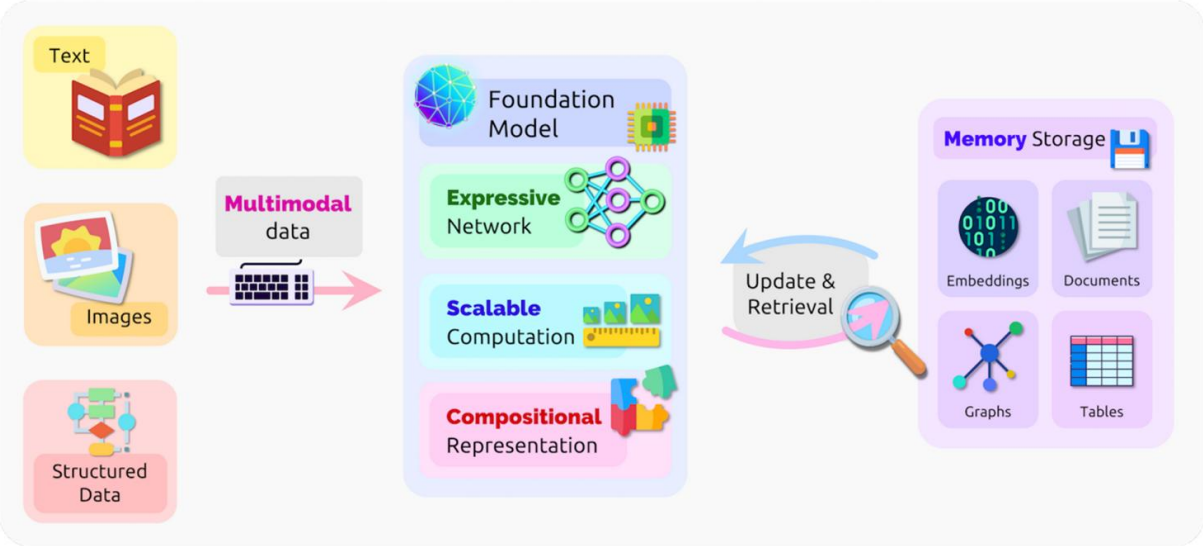
**从近乎无穷的可能中找出适当的组合**

# 什么是大模型?

❖ “大模型”通常指的是**参数量量级高**、**通用性强**的模型。这些模型在大规模数据上进行训练，具备**知识理解能力、逻辑推理能力、指令遵循能力**，并能适应广泛的下游任务。

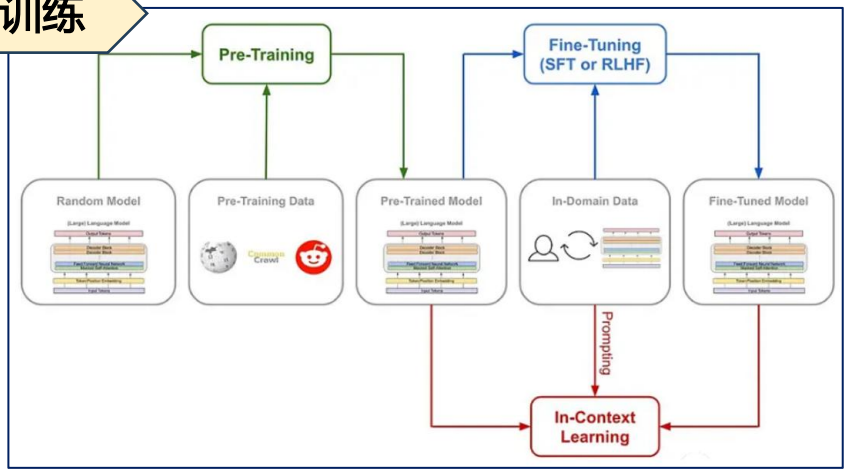
大模型具备以下优势：

- 快速适应新任务，无需额外训练，直接推理
- 一模型多用，处理复杂指令，提升交互体验
- 跨领域深度理解，提供高质量、多样化回答

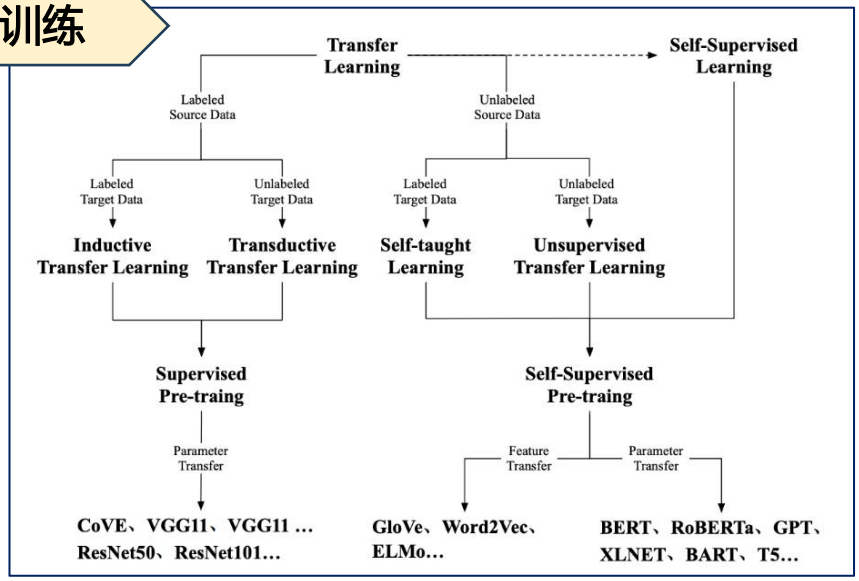


# 大模型是如何训练的

## 完整训练




## 预训练



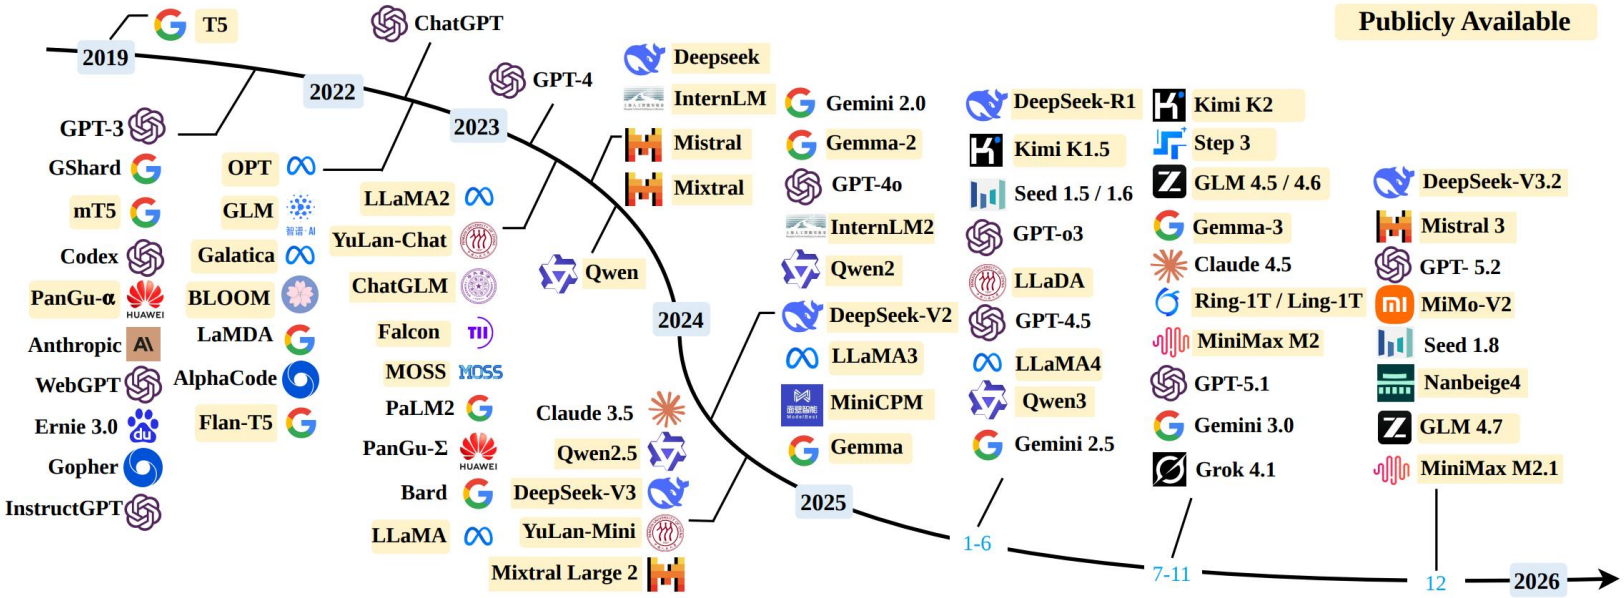

**预训练模型**是指在大规模数据集上预先进行训练的神经网络模型，通常在通用任务上学习到的特征可以被迁移到其他特定任务中。预训练模型的思想是利用大规模数据的信息来*初始化模型参数，然后通过微调或迁移学习，将模型适应在特定的目标任务上*。

## 为什么需要预训练模型?

1. 泛化能力强：大规模数据训练使模型具备更强的适应性和鲁棒性
2. 可迁移：通用特征可快速迁移到下游任务（如文本分类、问答系统）
3. 节省资源：预训练过程需大量计算资源和时间，复用预训练模型可避免重复训练

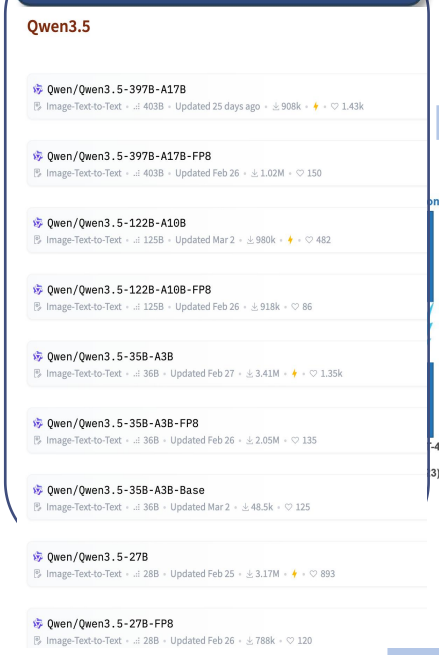
# 大模型的发展历程

- 2017年，Transformers架构问世，成为一切的起源...
- 2018年，GPT以及BERT问世，为Transformer在语言任务上的预训练奠定技术基础。
- 2019年至2022年，涌现大量大模型，模型迭代优化，参数规模高速增长。
- 2022年末，ChatGPT发布，象征着对话式人工智能进入了一个新阶段。
- 2023年，大模型的能力进一步加强，出现GPT-4、盘古等多模态大模型。
- 2024年初，Sora、GPT-4o等发布，进一步扩展了大模型的应用范围。
- 2024年底，大模型领域继续发展，国产大模型DeepSeek的发布，在全世界范围引起热议，让个性化大模型智能体发展备受关注。

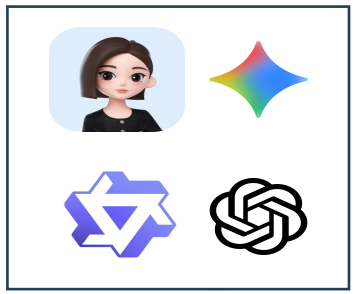


# 大模型的发展趋势

## 从小规模到大规模

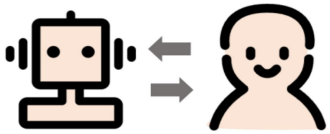



## 从单模态到多模态

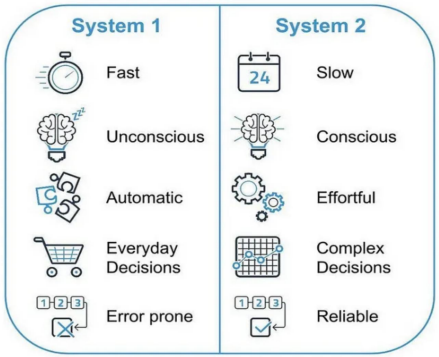


单模态　　多模态

## 从对话式大模型到智能体




## 推理能力持续进化




## 从学术研究到行业应用



医疗、金融、制造、
物流、教育、民生...

# 大模型工作原理

**一句话概括**：以词元（token）形式进行接龙

核心思想：文字、图片、语音、视频等内容均可以用有限个数的**基本单元**组合形成，这些基本单位可被称为词元(token)



文章
由文字所构成



图像
由像素所构成



语音
由取样点构成

| | | | |
|---|---|---|---|
| Token | 我 |  | 0.70 |

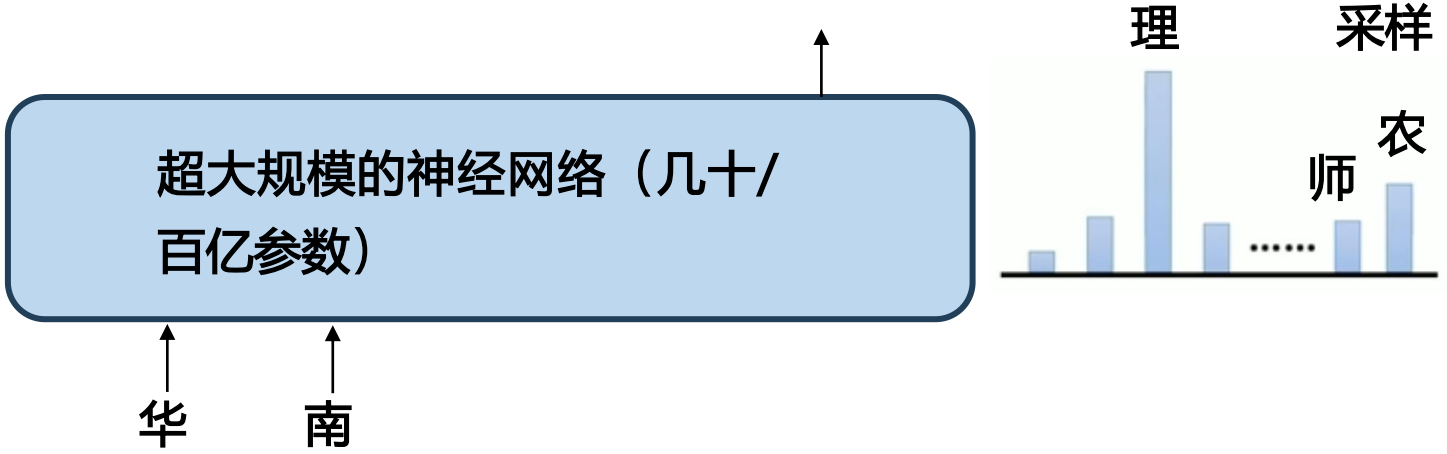
实现流程：给一串token，决定下一个token（选择题），循环往复

华南 → 理 ⇒ 华南理 → 工 ⇒ 华南理工 → 大 ⇒ ...

# 大模型工作原理

**一句话概括**：以词元（token）形式进行接龙

怎么决定下一个token：华南 → 理、农、师 ...?




**所有的任务**均可以组织成接龙形式：

翻译成英文：人工智能 → AI Artificial Intelligence

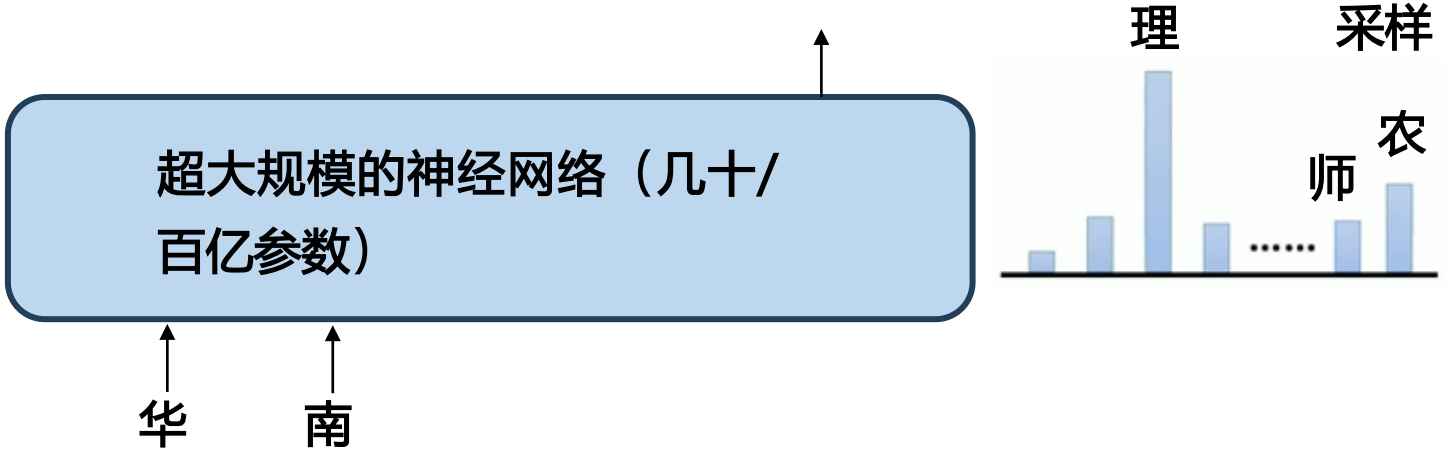
写一首七言绝句诗 → AI 远山衔日入烟霞,碧水东流带晚沙,...

这张图片是猫还是狗? → AI 这是一条狗

# 大模型工作原理

**一句话概括**：以词元（token）形式进行接龙

怎么决定下一个token：华南 → 理、农、师 ...?




**三个组成部份**：

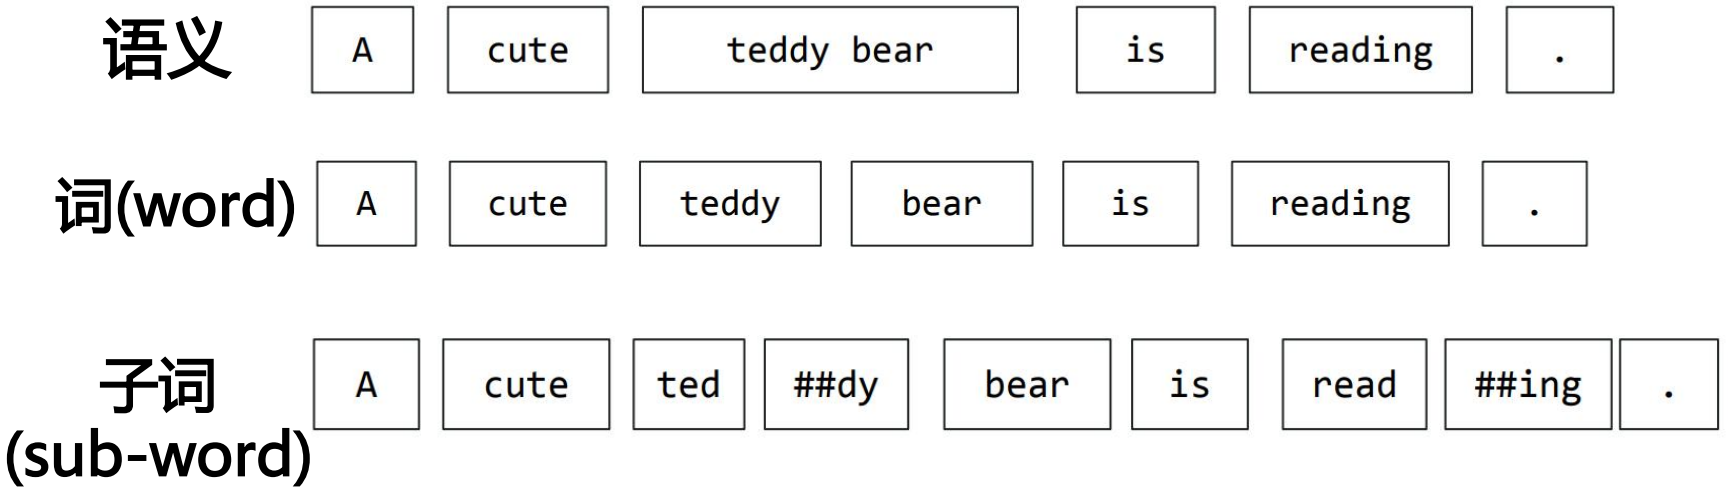
1.输入的token的划分和表示

2.模型架构

3.模型训练

# token的划分和表示

- 以下面句子为例：
  - A cute teddy bear is reading.




在英文中，一般用WordPiece或BPE来进行token划分

# token的划分和表示

- 子词的token划分方式具有更好的延展性：
  - taaaaasty -> taa## aaa## sty
  - laern -> la## ern## （拼写错误）
  - Transformerify -> Transformer## ify （新词）

# token的划分和表示

- 中文tokenization：

1.单字、标点等：1字=1token

“啊”，“。”，“好”

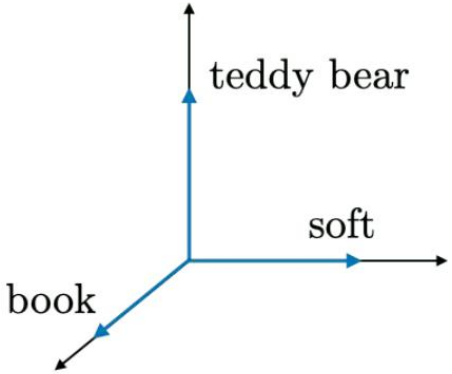
2.高频常用词组，多字=1token

“人工智能”，“深度学习”

# token的划分和表示

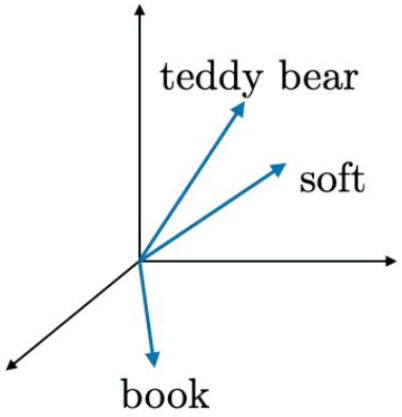
- Token的表示：

1.传统的自然语言处理/信息检索中常采用one-hot编码（TF-IDF，BM25等方法）




$$\text{soft} = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} \quad \langle \text{teddy bear}, \text{book} \rangle = 0 \quad \langle \text{teddy bear}, \text{soft} \rangle = 0$$

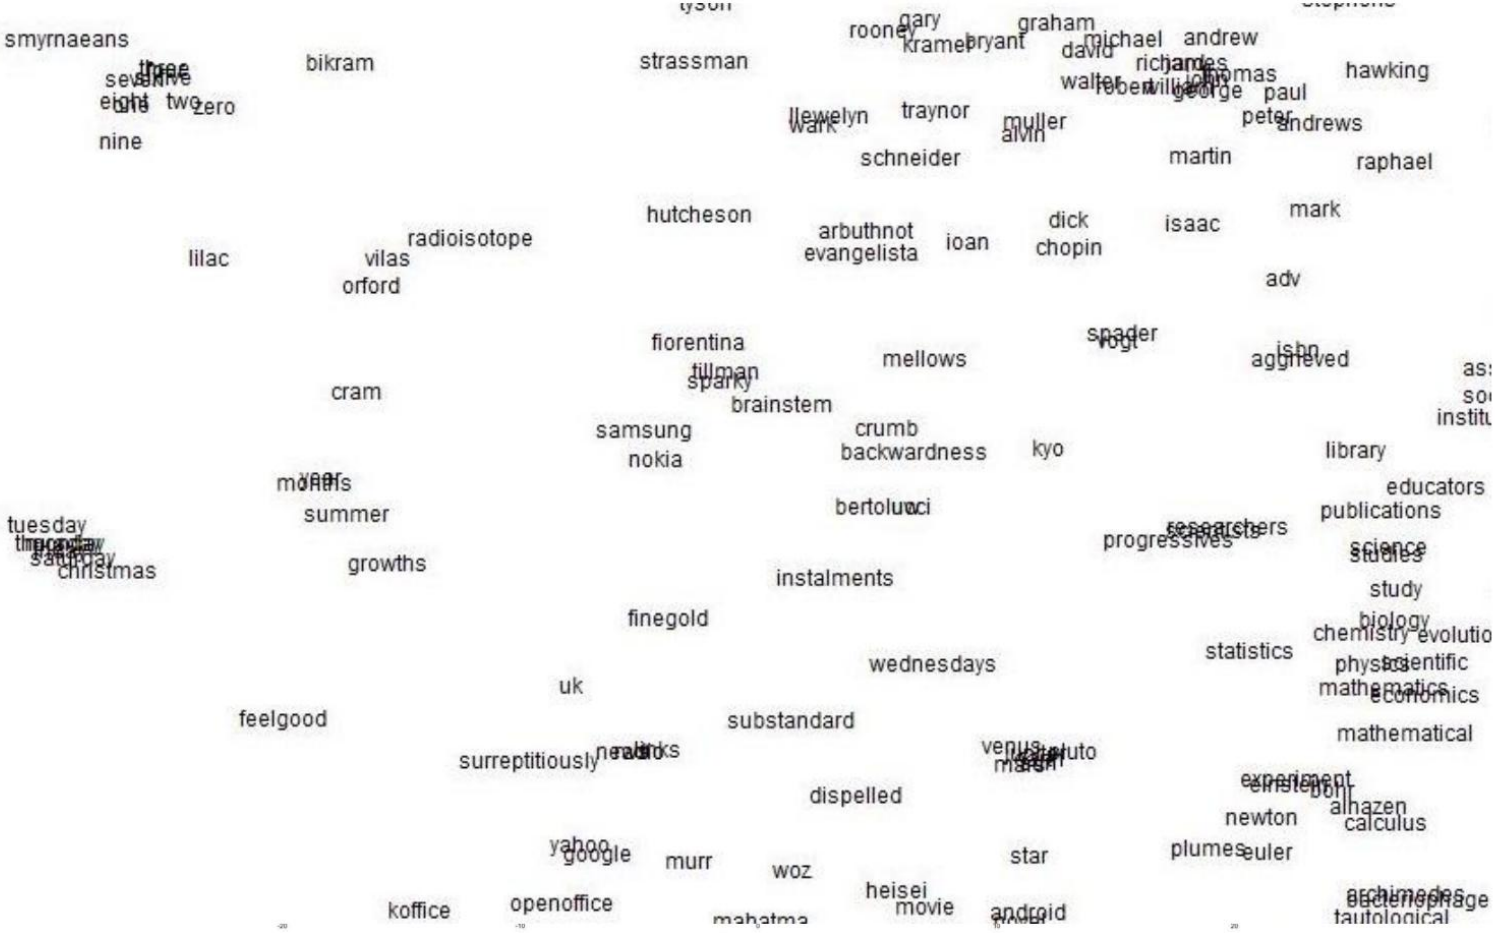
2.可学习的向量化表示




$$\text{soft} = \begin{pmatrix} 0.95 \\ 0.32 \\ 0.01 \end{pmatrix} \quad \langle \text{teddy bear}, \text{book} \rangle \sim 0 \quad \langle \text{teddy bear}, \text{soft} \rangle \sim 1$$

# token的划分和表示

## 相似的词语会有相似的向量表示



# 模型架构

- **神经序列模型**
  - 现代大模型的本质：语言模型（Language Model）

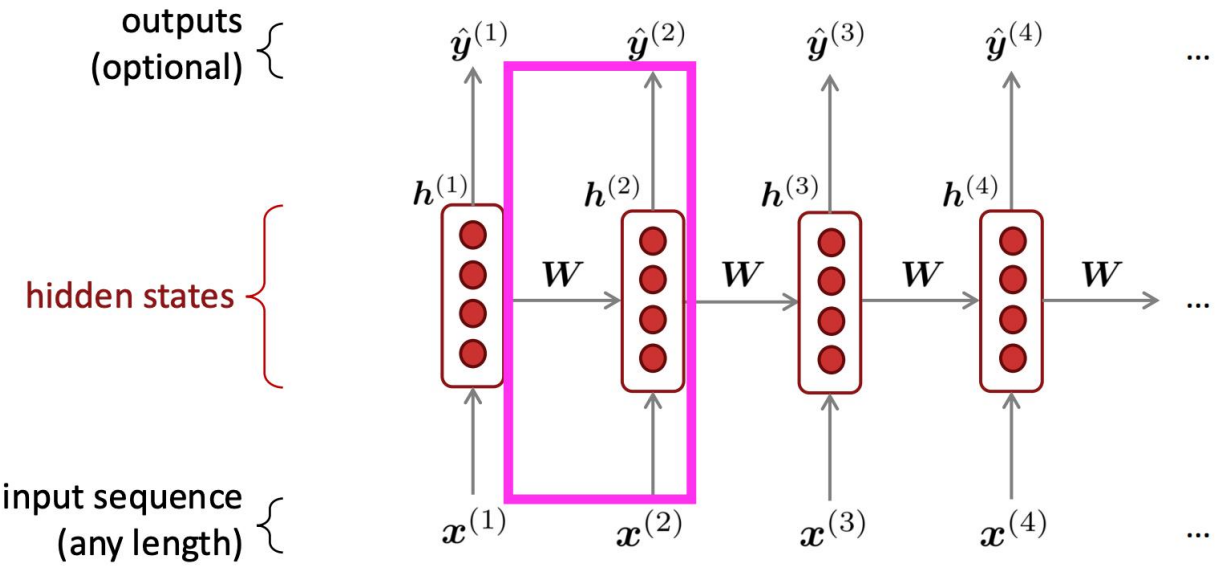
**A cute teddy bear is reading.**

$$P(\boldsymbol{x}^{(1)},\ldots,\boldsymbol{x}^{(T)}) = P(\boldsymbol{x}^{(1)}) \times P(\boldsymbol{x}^{(2)}|\ \boldsymbol{x}^{(1)}) \times \cdots \times P(\boldsymbol{x}^{(T)}|\ \boldsymbol{x}^{(T-1)},\ldots,\boldsymbol{x}^{(1)})$$
$$= \prod_{t=1}^{T} P(\boldsymbol{x}^{(t)}|\ \boldsymbol{x}^{(t-1)},\ldots,\boldsymbol{x}^{(1)})$$

# 模型架构

## ❖ 神经序列模型

- 循环神经网络（RNN）可追溯到80年代，进行具有序列信息的建模




output distribution

$$\hat{\boldsymbol{y}}^{(t)} = \text{softmax}\left(\boldsymbol{U}\boldsymbol{h}^{(t)} + \boldsymbol{b}_2\right) \in \mathbb{R}^{|V|}$$

hidden states

$$\boldsymbol{h}^{(t)} = \sigma\left(\boldsymbol{W}_h\boldsymbol{h}^{(t-1)} + \boldsymbol{W}_e\boldsymbol{e}^{(t)} + \boldsymbol{b}_1\right)$$

$\boldsymbol{h}^{(0)}$ is the initial hidden state

word embeddings

$$\boldsymbol{e}^{(t)} = \boldsymbol{E}\boldsymbol{x}^{(t)}$$

- 通过一个公共的权重W，时序性地进行建模处理

words / one-hot vectors

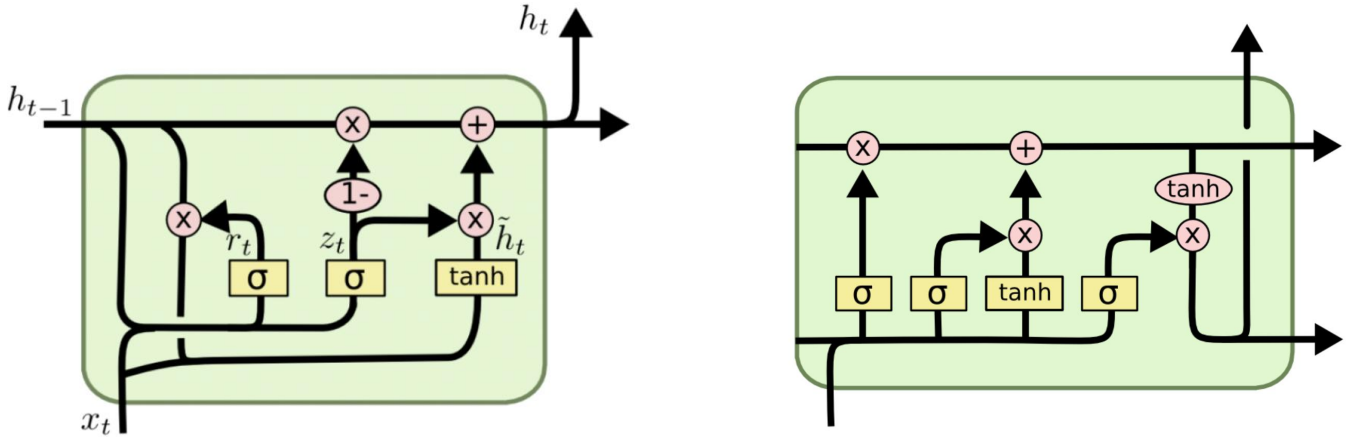
$$\boldsymbol{x}^{(t)} \in \mathbb{R}^{|V|}$$

来源：Stanford CS224N

# 模型架构

## ❖ 神经序列模型

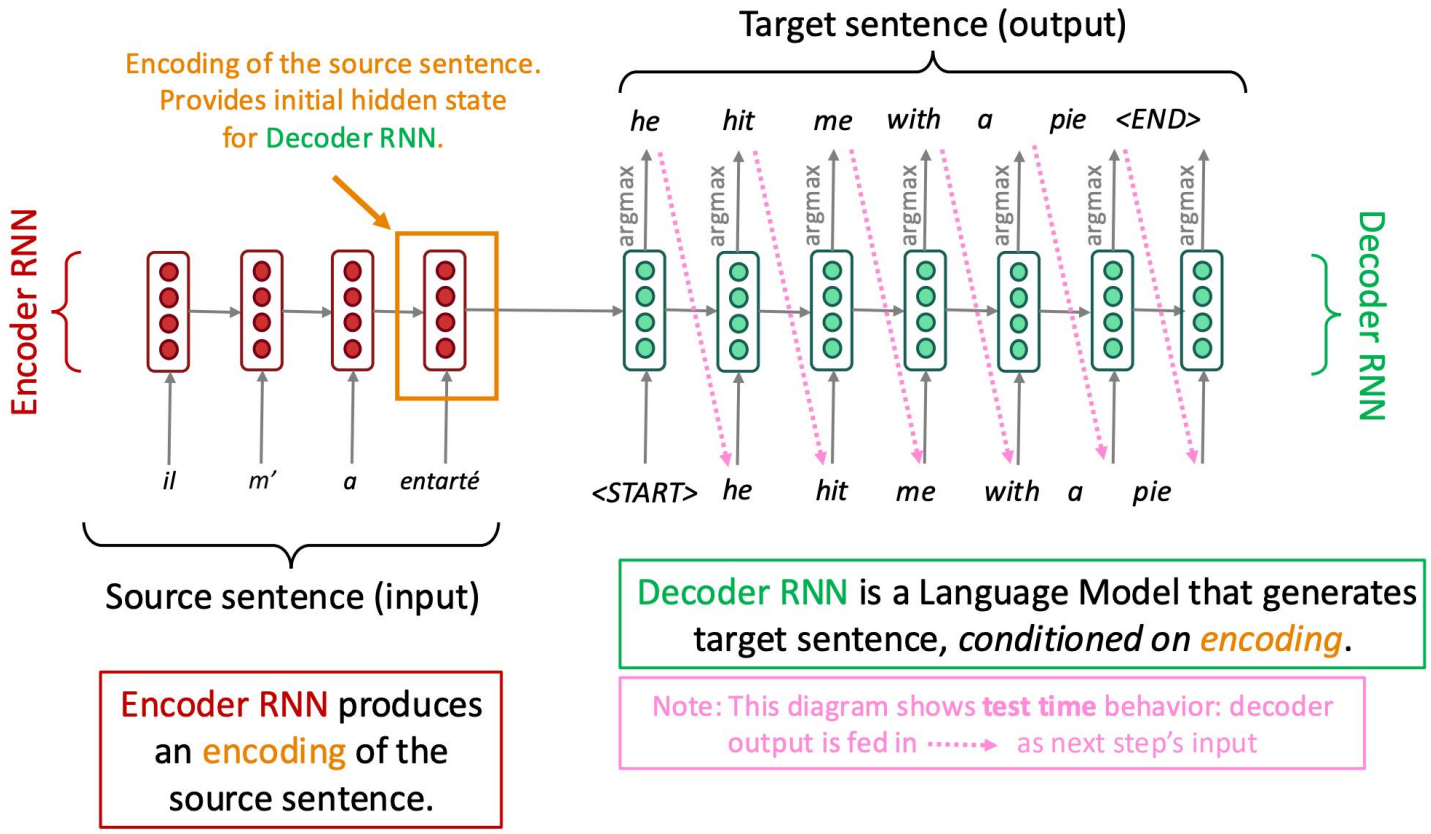
- 两种经典RNN变体：
  - GRU（Gated Recurrent Unit），LSTM(Long-Short Term Memory)




- RNN的局限：1. 梯度消失；2. 效率问题

# 模型架构

- 神经网络在NLP领域的第一次大规模成功落地应用：
  - Sequence-to-Sequence （Seq2Seq）模型在机器翻译中的应用
  - 2016年，Google翻译从统计学习方法转换为神经网络方法；到2018年所有公司的翻译模型都部署了神经翻译模型



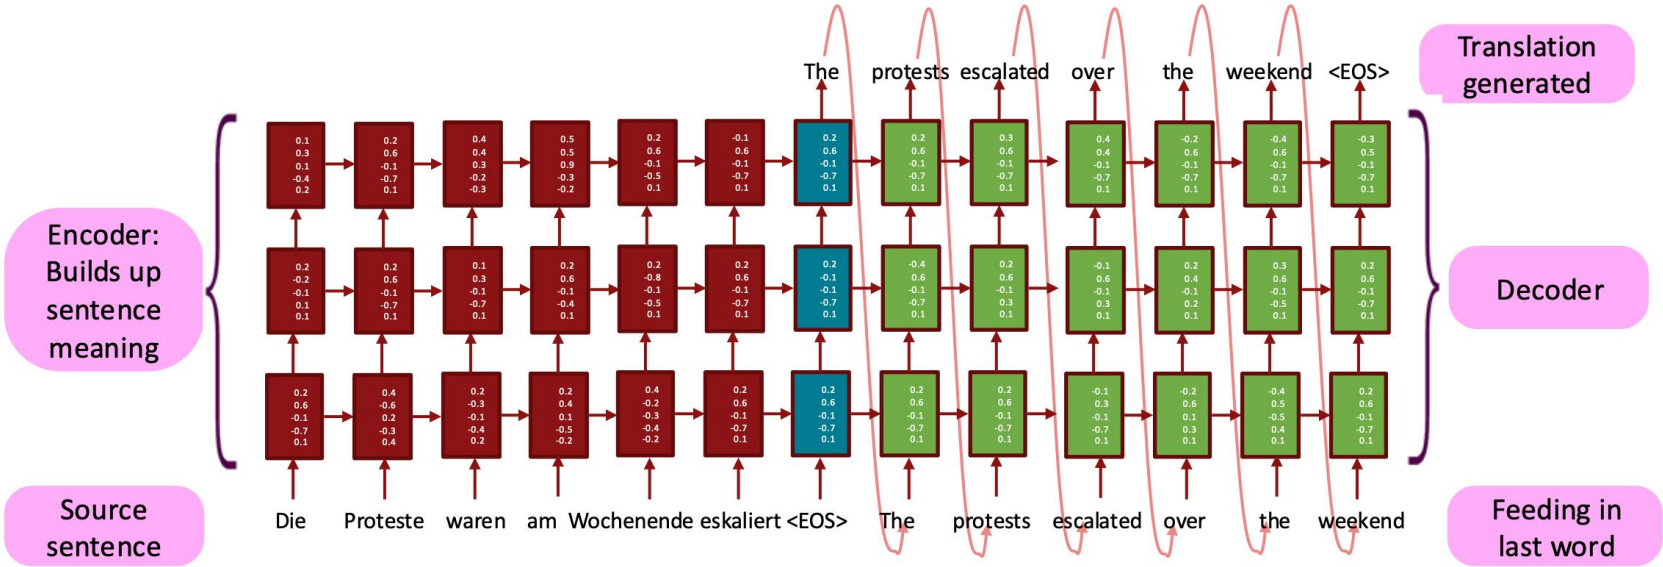

来源：Stanford CS224N

# 模型架构

- 神经网络在NLP领域的第一次大规模成功应用：
  - Seq2Seq也是一种语言模型（条件语言模型，conditional language model，也就是现在的对话模型）：

$$P(y|x) = P(y_1|x)\,P(y_2|y_1,x)\,P(y_3|y_1,y_2,x)\ldots P(y_T|y_1,\ldots,y_{T-1},x)$$

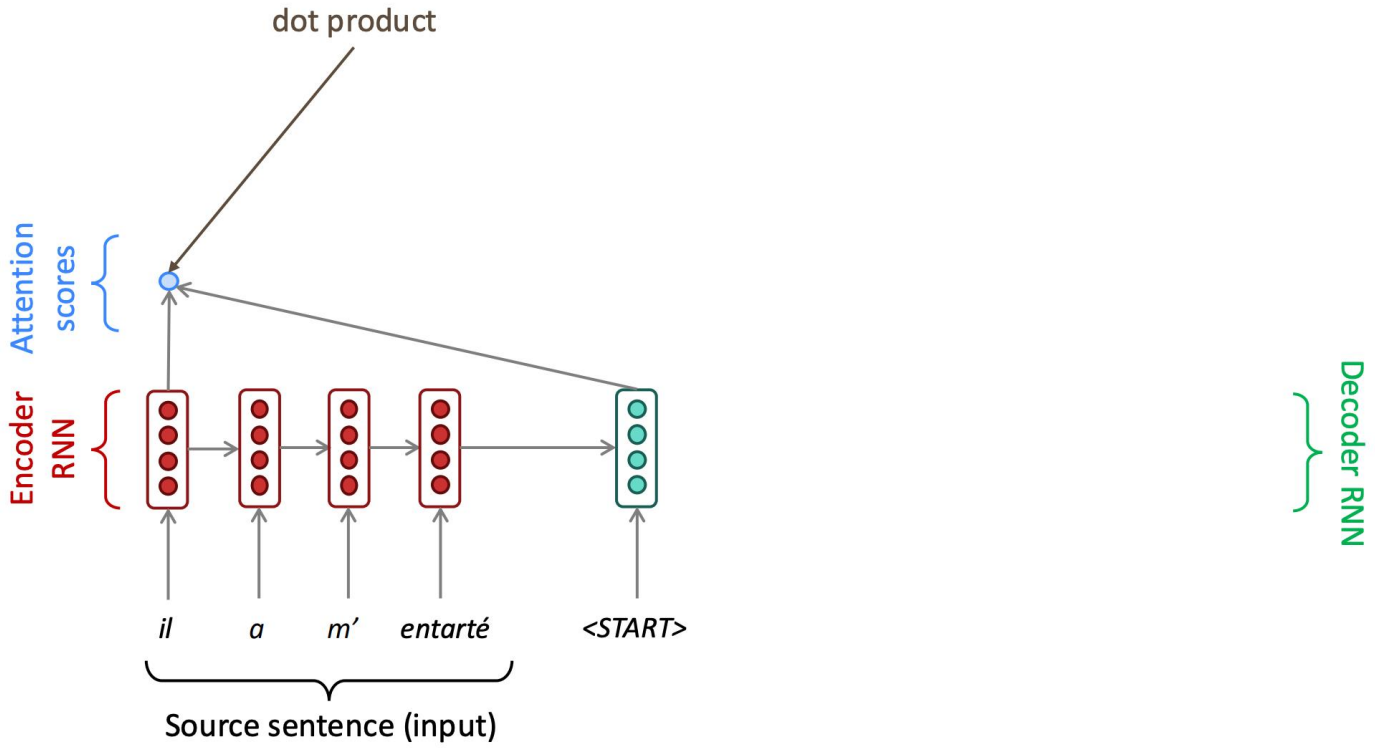
Probability of next target word, given target words so far and source sentence *x*




来源：Stanford CS224N

# 模型架构

- 注意力机制（Attention mechanism）：
  - 核心思想：在decoder的每一步，可以通过建立直接连接、选择性聚焦源序列中的特定部分
  - 本质：是对于源序列的一种加权平均

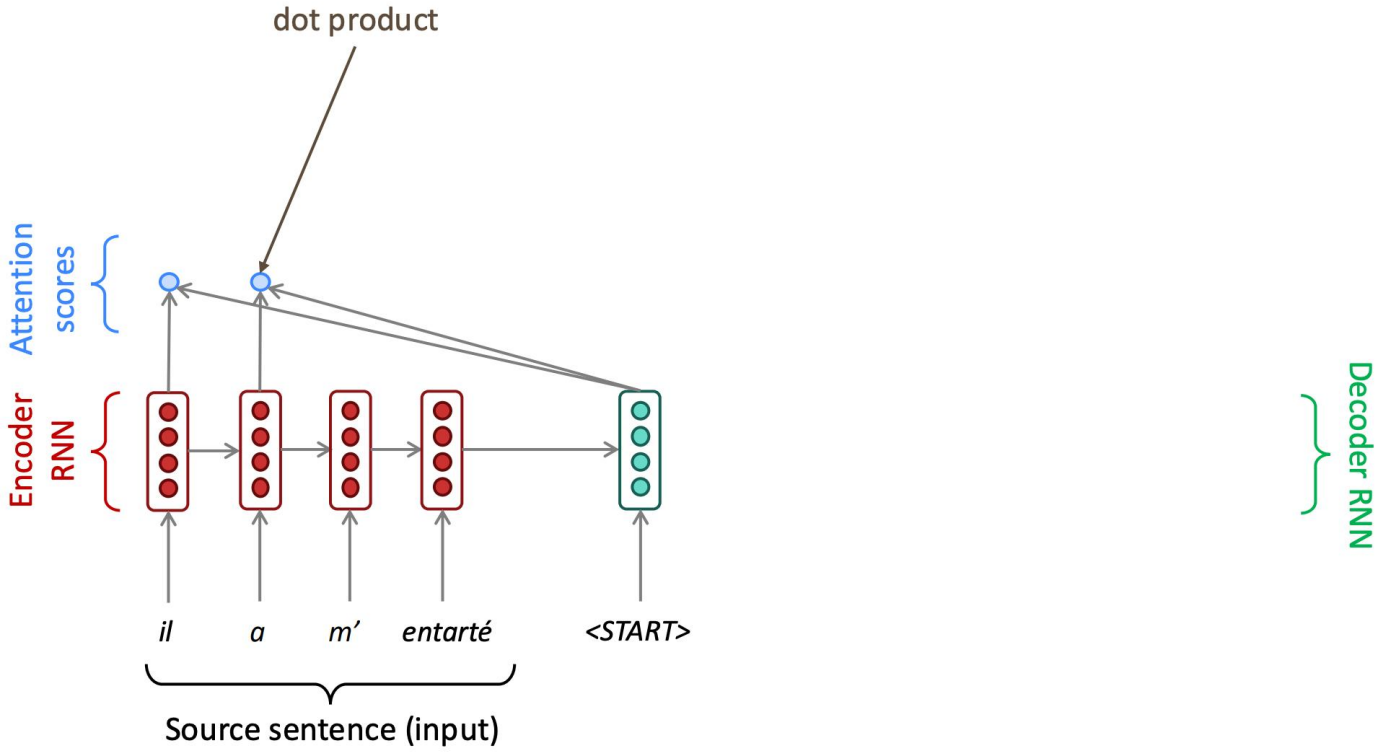



  - 可有效解决记忆问题和梯度消失问题

来源：Stanford CS224N

# 模型架构

- 注意力机制（Attention mechanism）：
  - 核心思想：在decoder的每一步，可以通过建立直接连接、选择性聚焦源序列中的特定部分
  - 本质：是对于源序列的一种加权平均

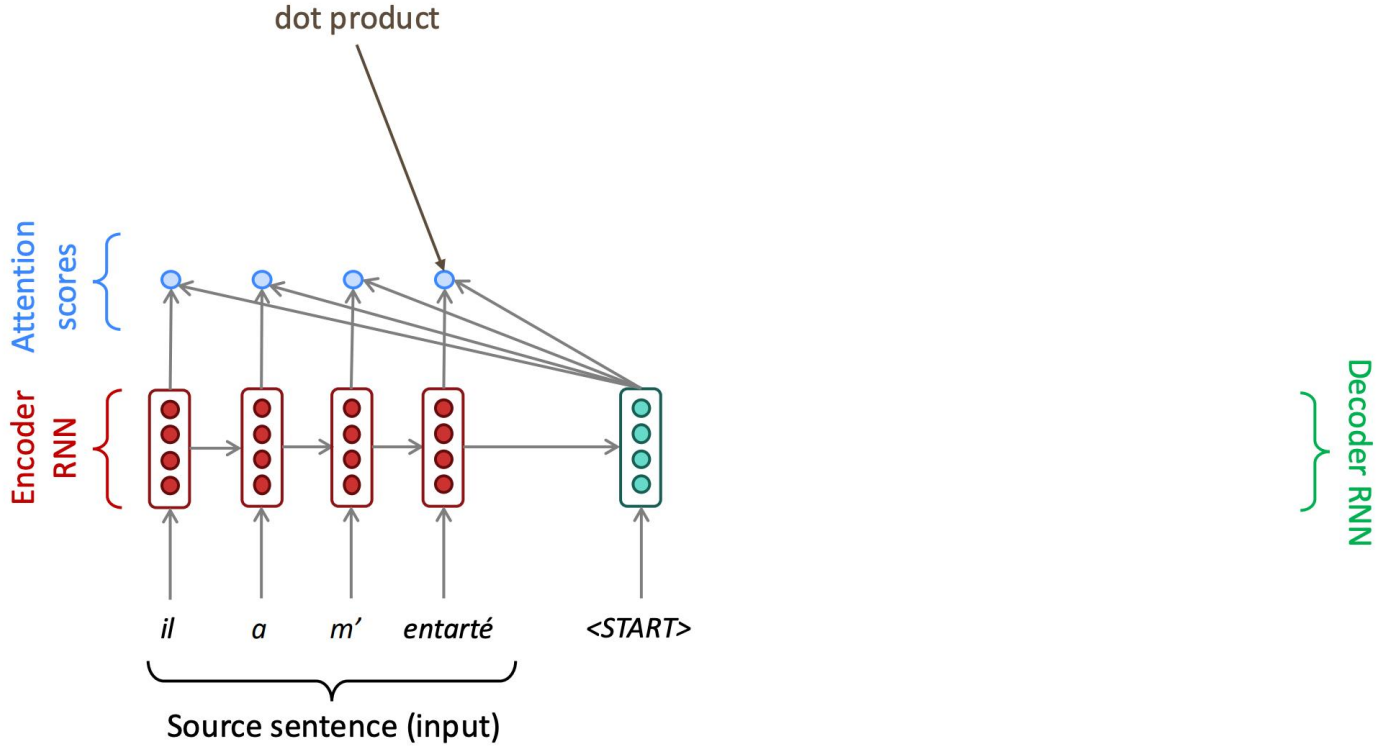



  - 可有效解决记忆问题和梯度消失问题

来源：Stanford CS224N

# 模型架构

- 注意力机制（Attention mechanism）：
  - 核心思想：在decoder的每一步，可以通过建立直接连接、选择性聚焦源序列中的特定部分
  - 本质：是对于源序列的一种加权平均

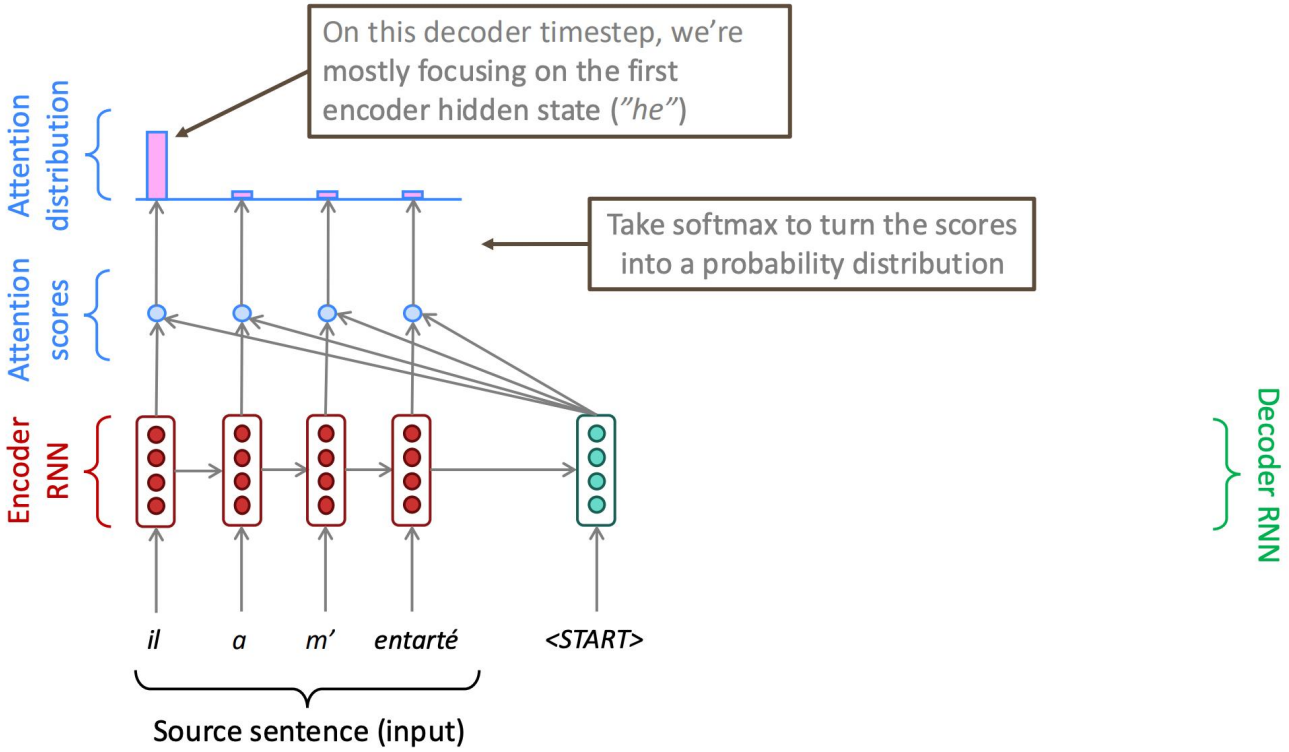



  - 可有效解决记忆问题和梯度消失问题

来源：Stanford CS224N

# 模型架构

- 注意力机制（Attention mechanism）：
  - 核心思想：在decoder的每一步，可以通过建立直接连接、选择性聚焦源序列中的特定部分
  - 本质：是对于源序列的一种加权平均

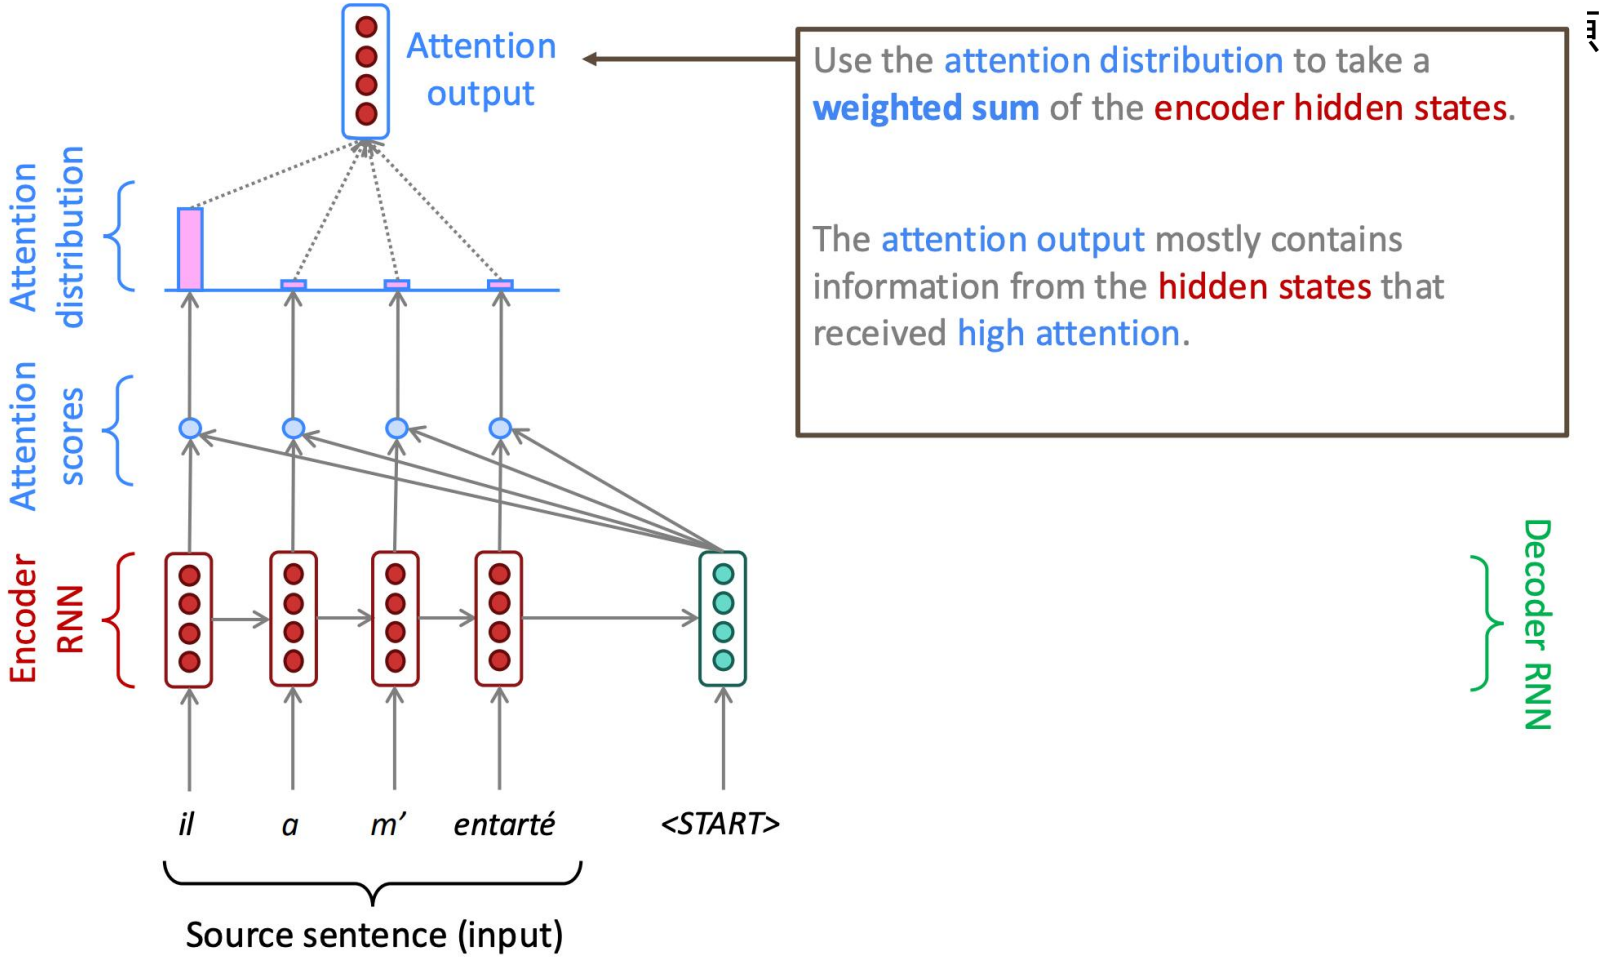



  - 可有效解决记忆问题和梯度消失问题

来源：Stanford CS224N

# 模型架构

- 注意力机制（Attention mechanism）：

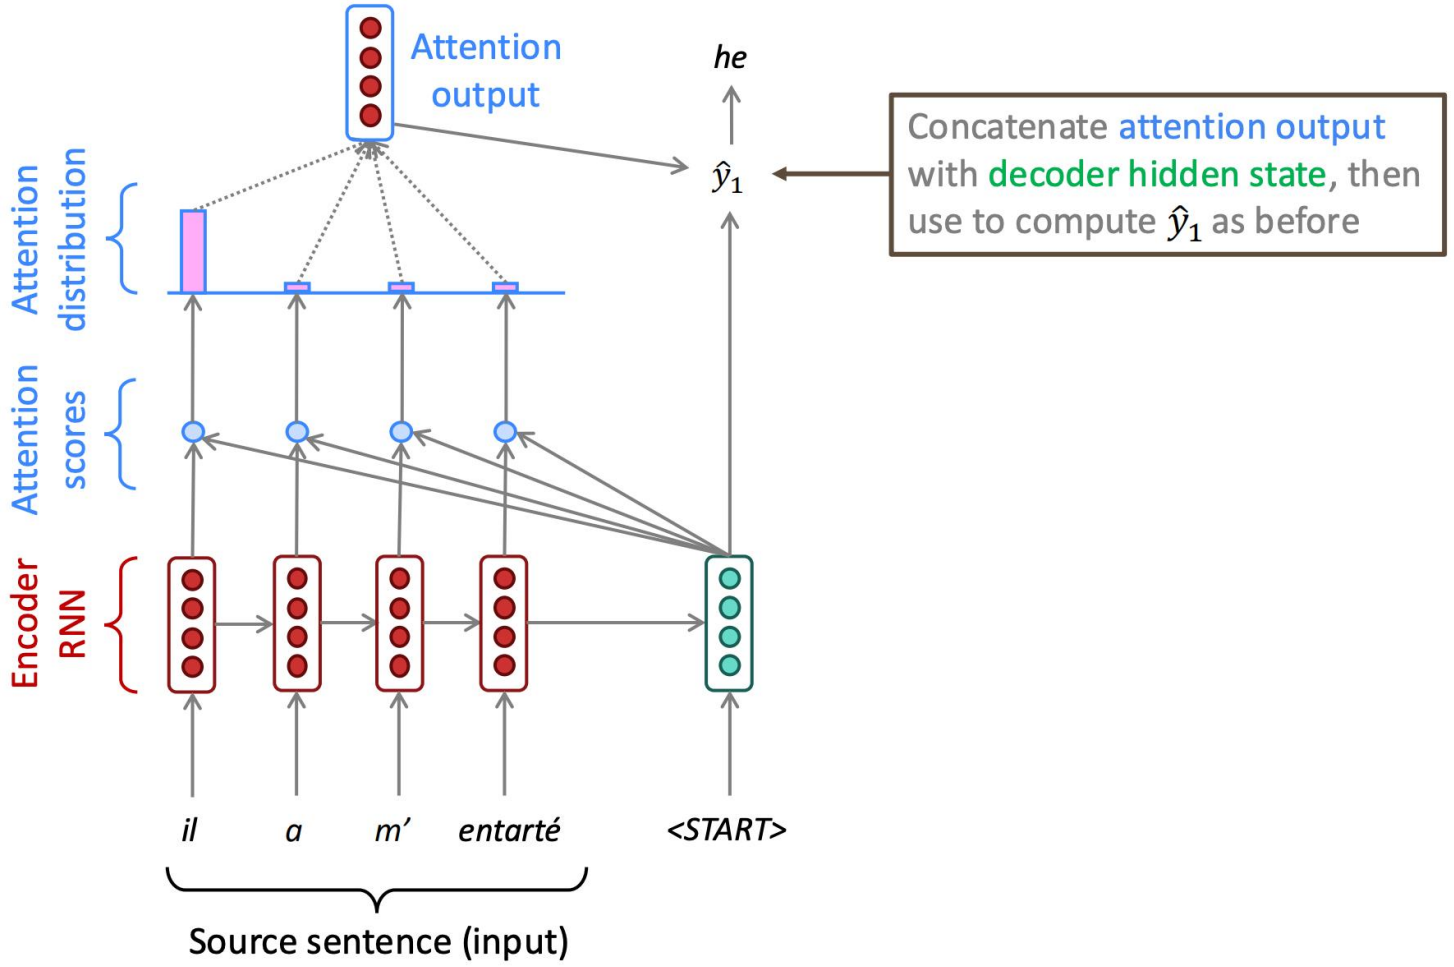



- 可有效解决记忆问题和梯度消失问题

来源：Stanford CS224N

# 模型架构

- 注意力机制（Attention mechanism）：

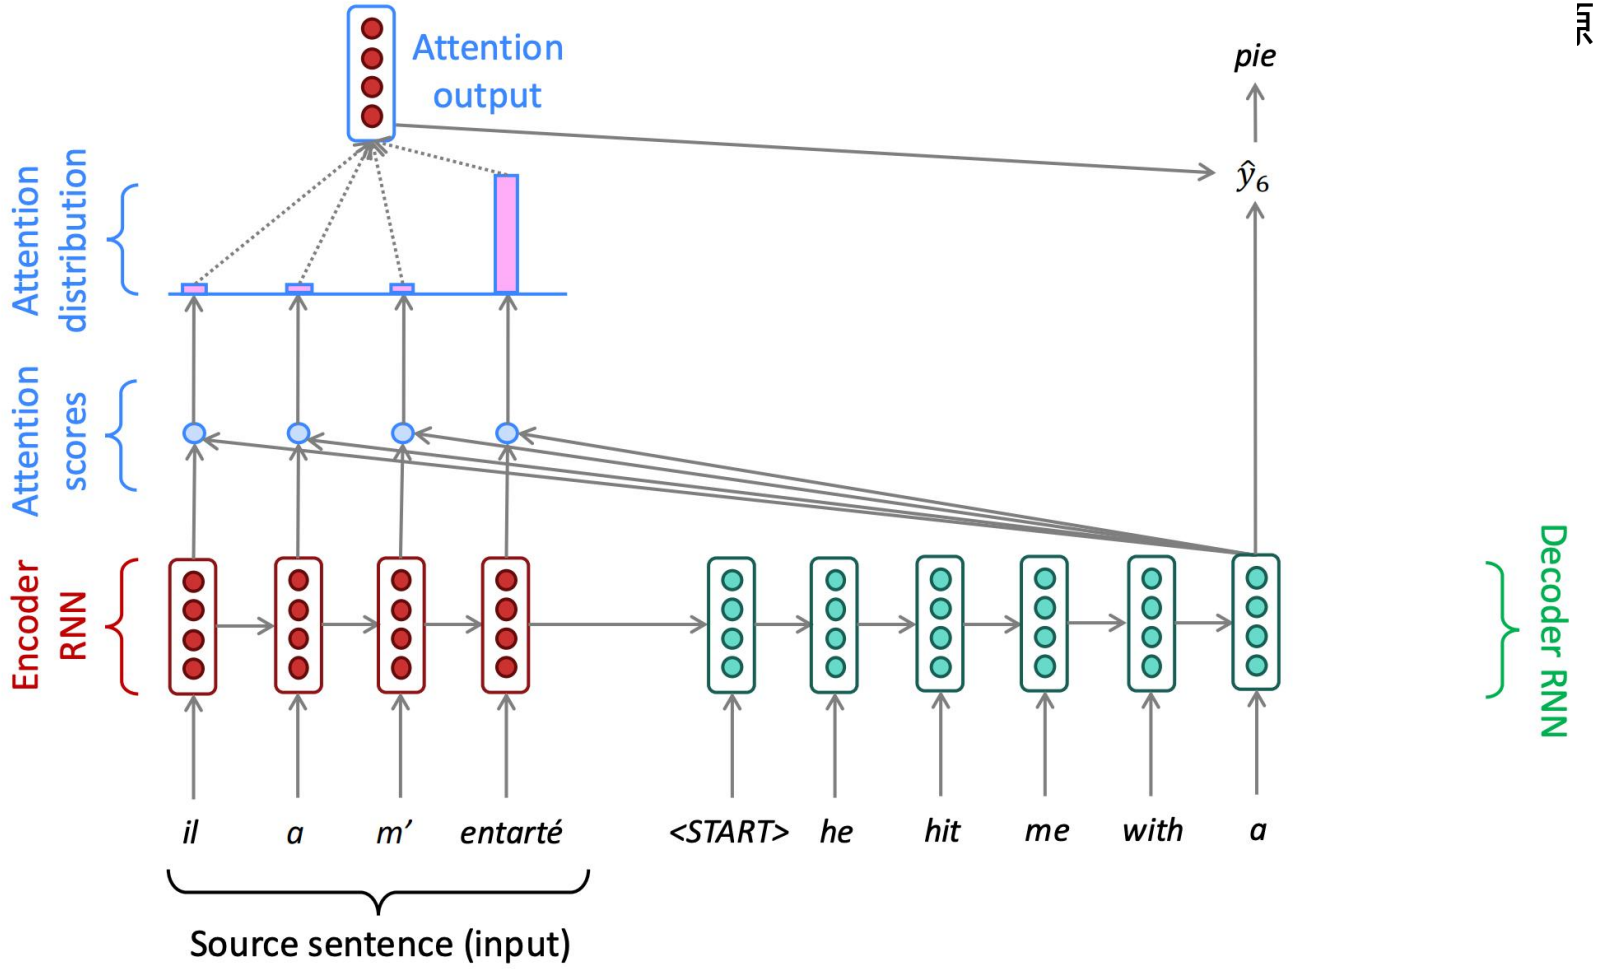



  - 可有效解决记忆问题和梯度消失问题

来源：Stanford CS224N

# 模型架构

- 注意力机制（Attention mechanism）：




- 可有效解决记忆问题和梯度消失问题

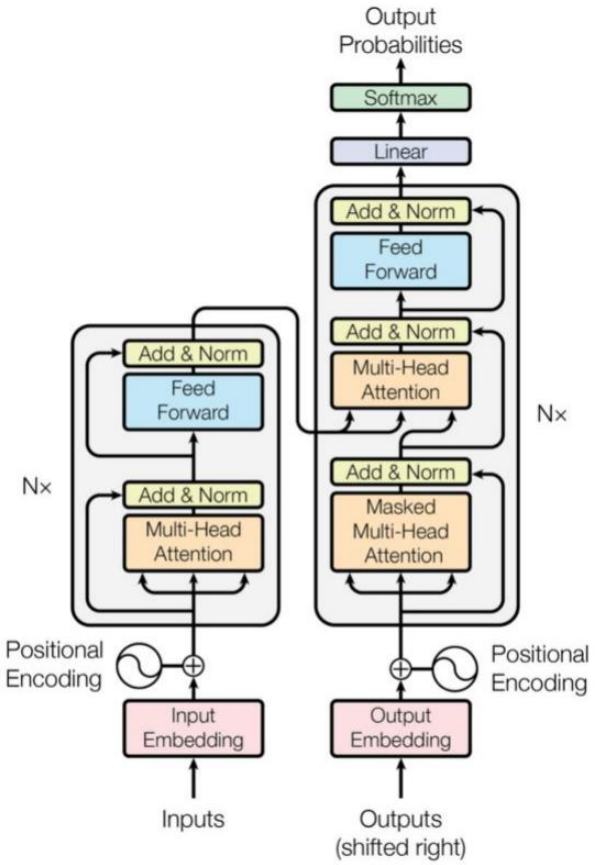
来源：Stanford CS224N

# 模型架构

- **注意力机制（Attention mechanism）：**
  - Attention机制的通用定义：给定一组value向量，和一个query向量，attention是一种根据query向量计算value向量加权平均的机制
  - 在Seq2Seq中，每一个decoder的隐状态（可视为query）会与所有的encoder隐状态（可视为value）进行计算
  - 传统序列模型仍然需要一步步进行序列处理

# 模型架构

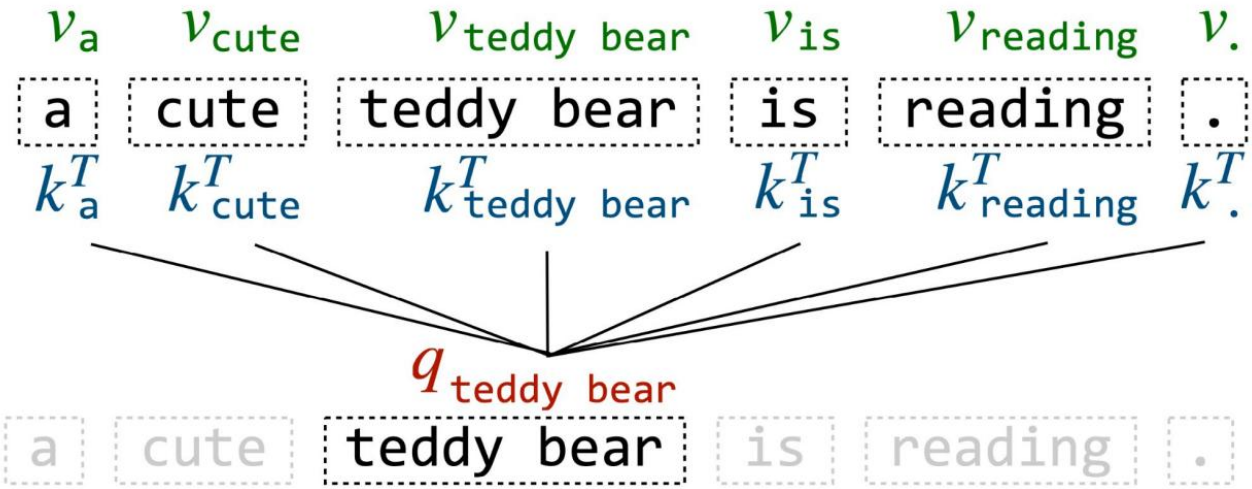
- Transformer模型：
  - 可将传统的Seq2Seq中的Encoder和Decoder中的RNN模块全部用Attention来替换
  - 一次性处理完整个序列




来源：Attention is all you need. NIPS 2017

# 模型架构

- Transformer模型：
  - 可将传统的Seq2Seq中的Encoder和Decoder中的RNN模块全部用Attention来替换
  - 一次性处理完整个序列:

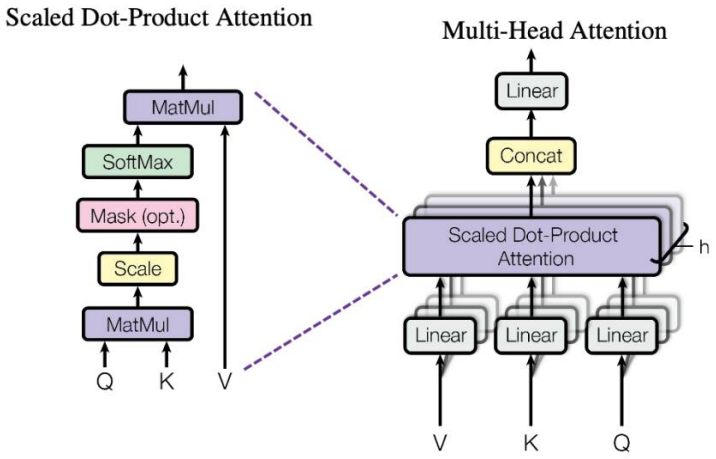


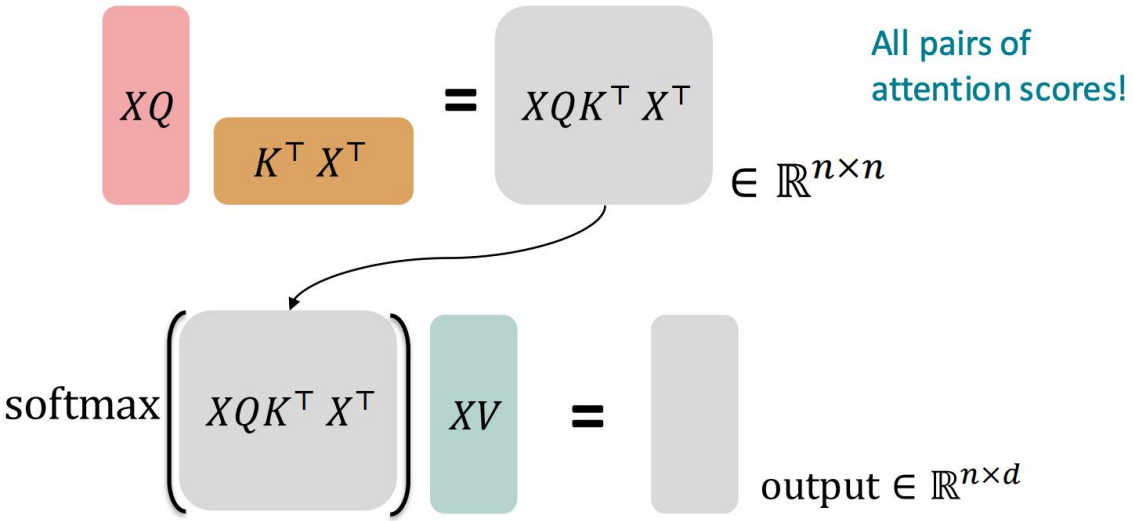

$$\text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

来源：Attention is all you need. NIPS 2017

# 模型架构

- Transformer模型：
  - 可将传统的Seq2Seq中的Encoder和Decoder中的RNN模块全部用Attention来替换
  - 一次性处理完整个序列




来源：Stanford CS224N

# 模型架构

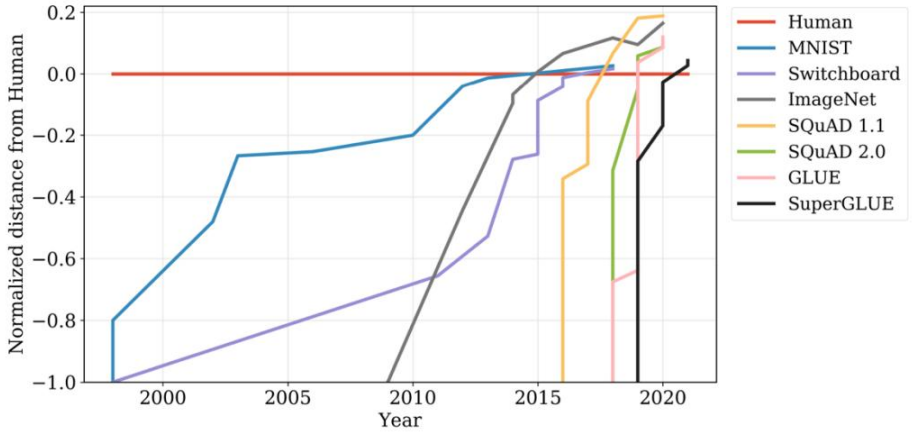
- **Transformer模型：**
  - **其他模块：**
    - positional encoding (sinusoidal, RoPE)
    - (Masked) self-attention + FFN
    - Residual connection, Layer Normalization

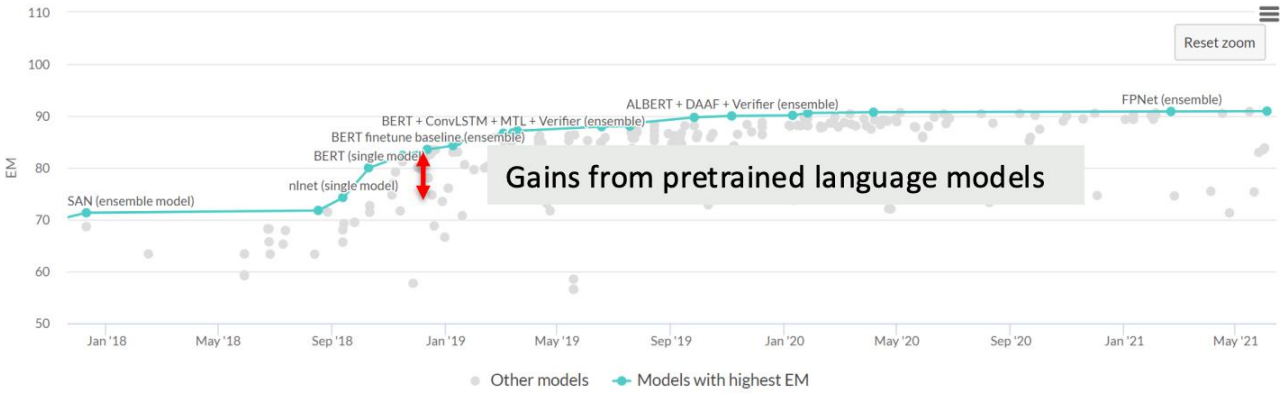
  为什么要这样设计？每个模块都有内在的原因

❖ 自行在课后了解细节

# 模型训练

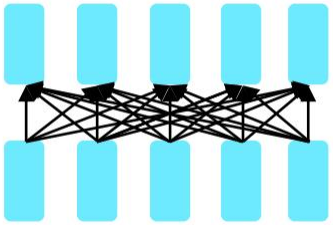
- 不同于传统的监督学习，Transformer架构的优势的体现在模型预训练中
- 自2018年以来，预训练已成为NLP领域的范式做法；几乎所有的NLP模型都是用预训练参数来初始化



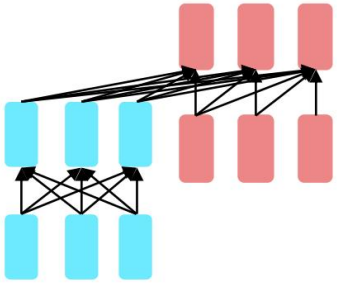
# 模型预训练

- **三种基于Transformer的预训练类型**
  - Encoder（BERT，ERNIE，RoBERTa系列）



- 可以获得双向的上下文，可基于未来
- 主要目的是为提取contextualized embedding，用于下游继续微调

  - Encoder-Decoder（T5系列）

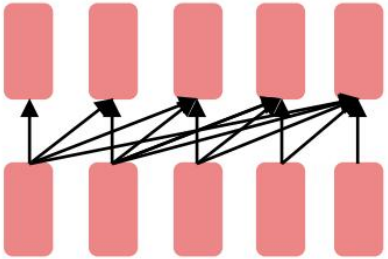


- 主要目的是用来text2text的输出
- 类似于语言模型，但Encoder部份的内容不做为训练目标

来源：Stanford CS224N

# 模型预训练

- 三种基于Transformer的预训练类型
  - Decoder（GPT系列，现在几乎所有的大模型）



- 语言模型的定义
- 对语言生成最适配，不能看到未来的内容（对应Transformer模型Decoder中的masked self-attention部份）

思考：为什么Decoder类型取代了逐渐取代了前两者?

来源：Stanford CS224N

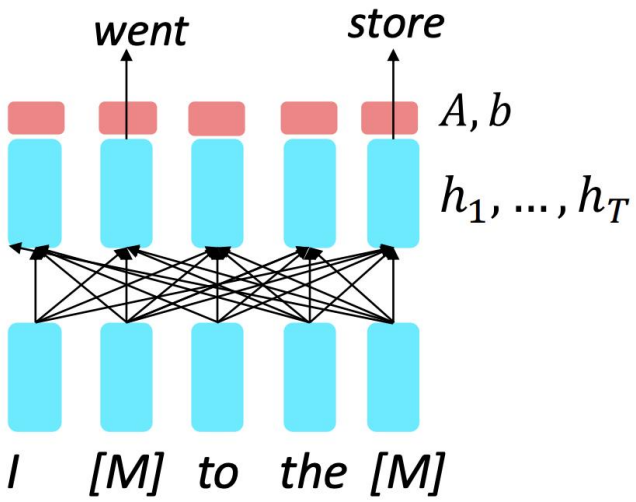
# 模型预训练

- 三种基于Transformer的预训练类型
  - Encoder（BERT，ERNIE，RoBERTa系列）

- 由于encoder能看到双向上下文，所以不是真正的语言模型（Language model），天然无法适配生成任务

- 如何训练?
  - 将一些词语做掩码，然后预测这些词
  - 这种训练方式被称为Masked language modeling

$$h_1, \ldots, h_T = \text{Encoder}(w_1, \ldots, w_T)$$
$$y_i \sim Aw_i + b$$




来源：Stanford CS224N

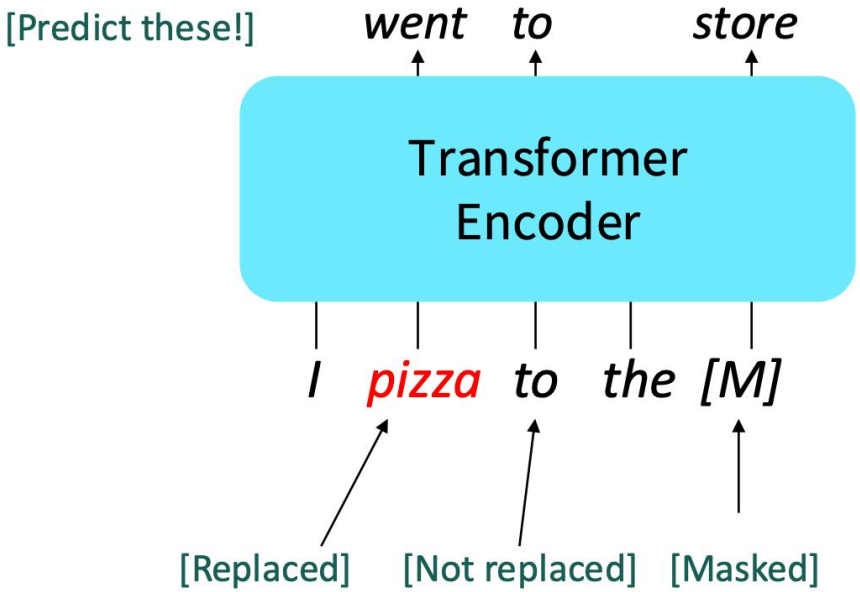
# 模型预训练

- **三种基于Transformer的预训练类型**
  - Encoder（BERT，ERNIE，RoBERTa系列）

**BERT中的训练细节：**

- 预测15%的token，其中：
  - 80%替换成[MASK]
  - 10%替换成一个随机token
  - 10%不做替换（但依然进行预测）

- 原理：防止模型过度依赖 Mask 机制，促使其也为未被遮蔽的词学习高质量的表示。因为在下游任务微调时并不存在 [MASK] 标记。



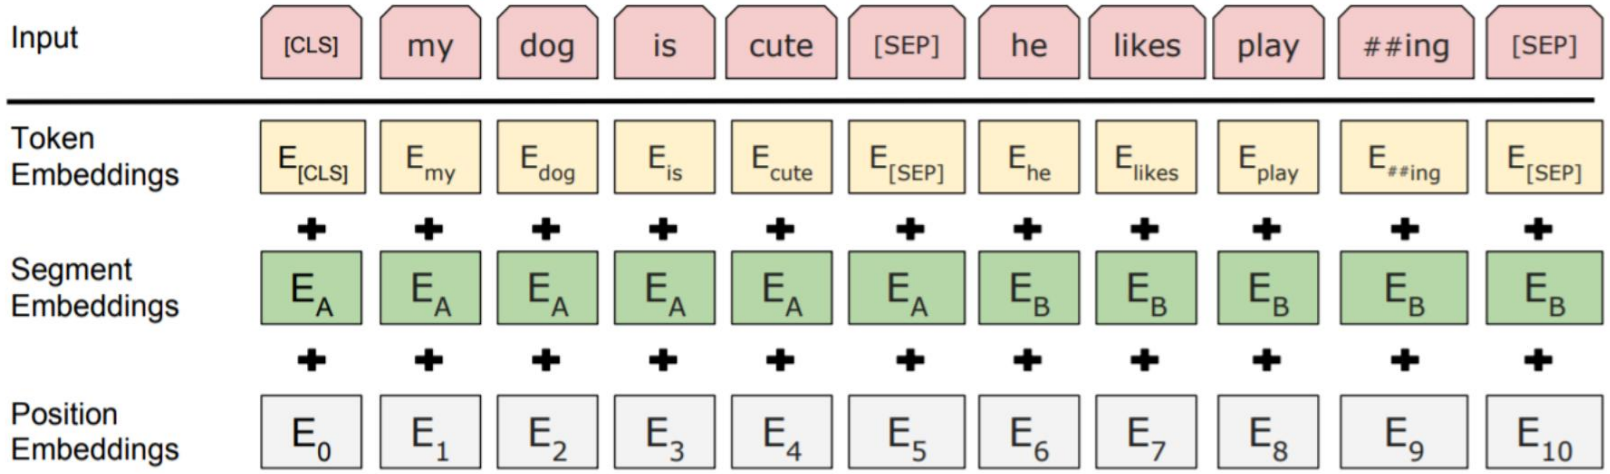

来源：Stanford CS224N

# 模型预训练

- **三种基于Transformer的预训练类型**
  - Encoder（BERT，ERNIE，RoBERTa系列）

**BERT中的训练细节：**

- 预测一个句子是否和另一个句子存在前后关系（后被证明没有收益）



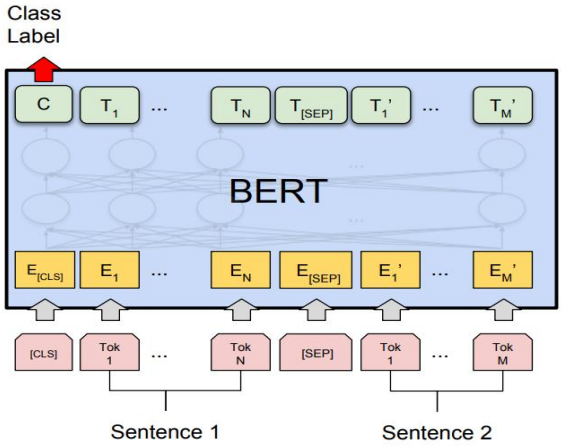
# 模型预训练

- **三种基于Transformer的预训练类型**
  - Encoder（BERT，ERNIE，RoBERTa系列）

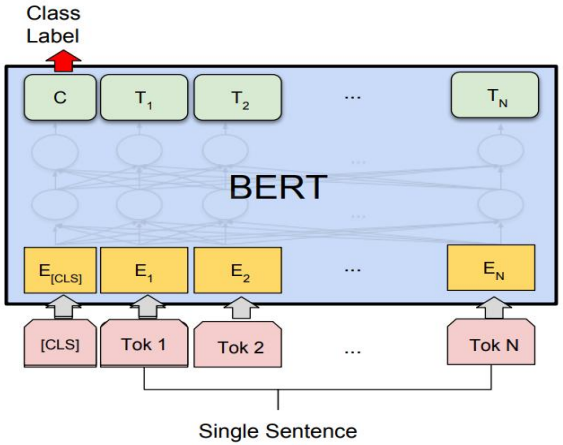
**BERT模型：**

- BERT-base: 12 layers, 768-dim hidden states, 12 attention heads, 110 million params.
- BERT-large: 24 layers, 1024-dim hidden states, 16 attention heads, 340 million params

**BERT在下游任务的微调**：训练一个很小的任务头（linear probing）




(a) Sentence Pair Classification Tasks: MNLI, QQP, QNLI, STS-B, MRPC, RTE, SWAG

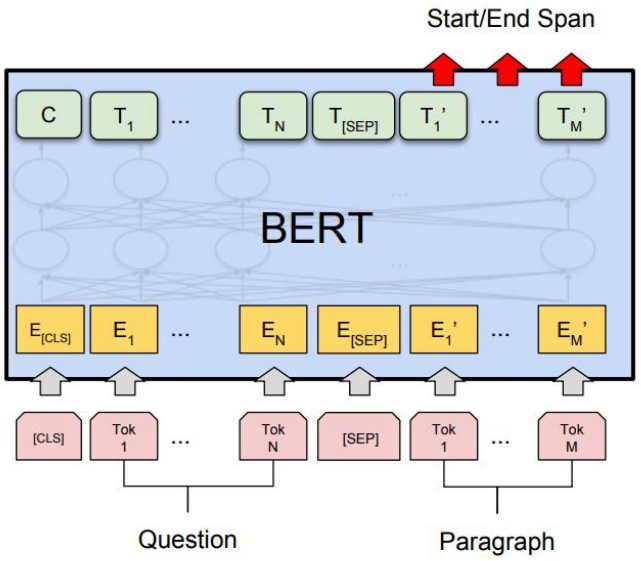



(b) Single Sentence Classification Tasks: SST-2, CoLA

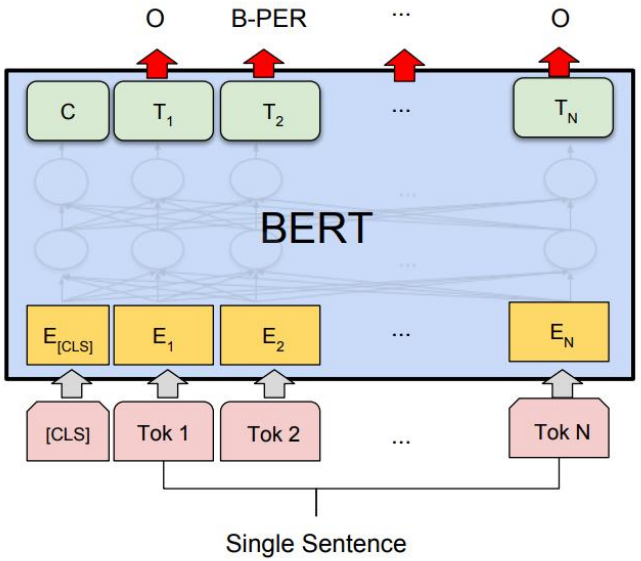
# 模型预训练

- **三种基于Transformer的预训练类型**
  - Encoder（BERT，ERNIE，RoBERTa系列）

**BERT在下游任务的微调**：训练一个很小的任务头（linear probing）




(c) Question Answering Tasks: SQuAD v1.1




(d) Single Sentence Tagging Tasks: CoNLL-2003 NER

# 模型预训练

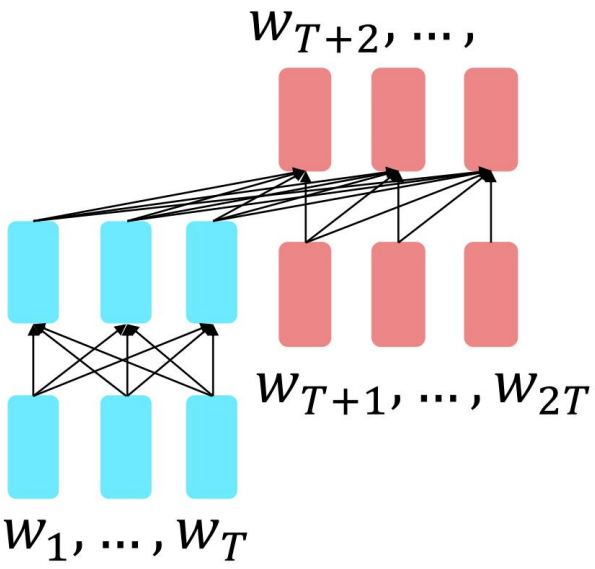
## ■ 三种基于Transformer的预训练类型

- Encoder-Decoder（T5系列）

- encoder能看到双向上下文，decoder无法看到未来内容；结合语言模型和双向上下文优势

- 如何训练?
  - decoder部分的做masked span还原训练

$$h_1, \ldots, h_T = \text{Encoder}(w_1, \ldots, w_T)$$
$$h_{T+1}, \ldots, h_2 = Decoder(w_1, \ldots, w_T, h_1, \ldots, h_T)$$
$$y_i \sim Ah_i + b, i > T$$




来源：Stanford CS224N

# 模型预训练

- **三种基于Transformer的预训练类型**
  - Encoder-Decoder（T5系列）

**T5中的训练细节：**

- 将不同长度的片段进行掩码，在decoder部分进行预测还原




- 与BERT比，能更好以生成方式来完成任务

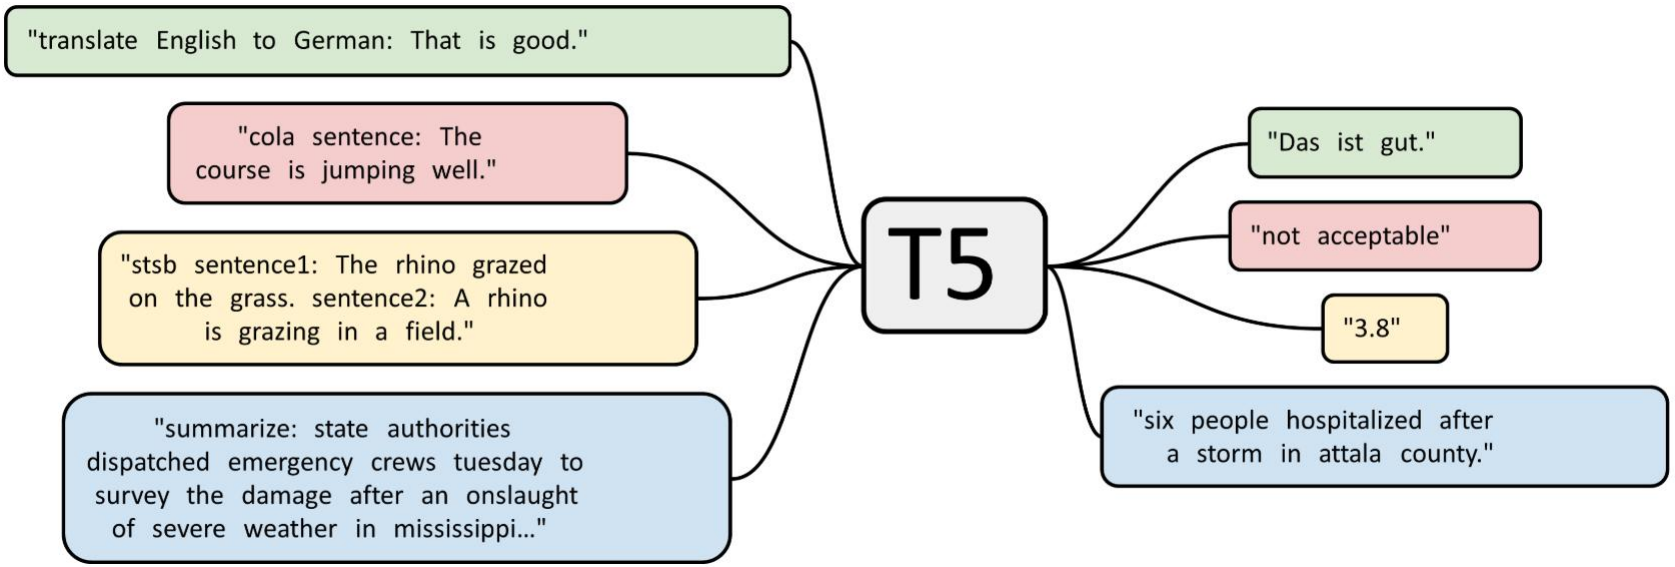
来源：Stanford CS224N

# 模型预训练

- **三种基于Transformer的预训练类型**
  - Encoder-Decoder（T5系列）

**T5中的训练细节：**

- 用不同的prefix来表示不同任务，进行训练：
  - 翻译前缀：translate English to German
  - 分类前缀：cola sentence
  - 摘要前缀： summarize
- 模型大小：Base 220million，Large 770million，XL 3B，XXL 11B



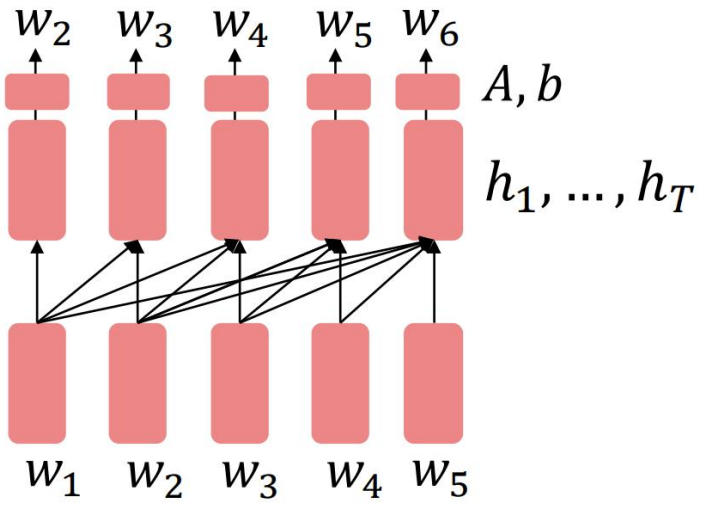
# 模型预训练

- 三种基于Transformer的预训练类型
  - Decoder（GPT系列）

- 仅能看到到当前为止的词，无法看到未来内容；完全与语言模型的目标对齐

- 如何训练?
  - 进行语言模型的训练
  - 所有的任务都可作为生成任务

$$h_1, \ldots, h_T = \text{Decoder}(w_1, \ldots, w_T)$$
$$w_t \sim Ah_{t-1} + b$$




来源：Stanford CS224N

# 模型预训练

- 三种基于Transformer的预训练类型
  - Decoder（GPT系列）

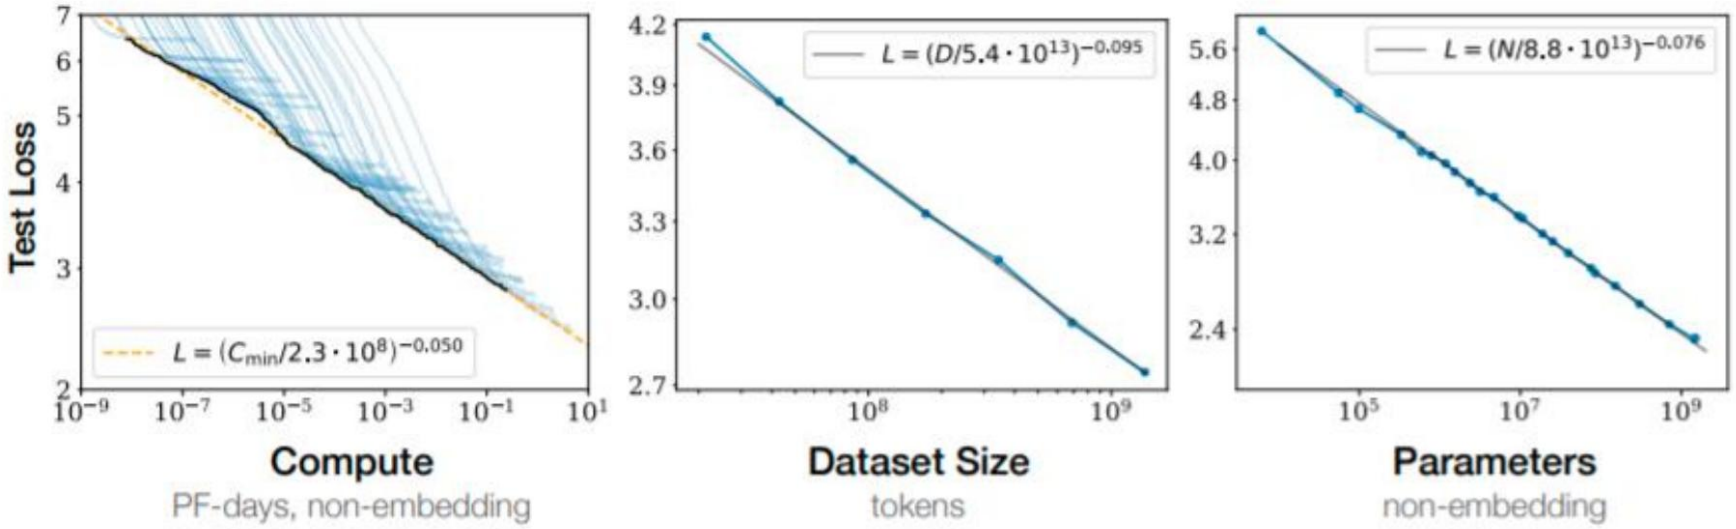
- GPT-1（2018）：12层Transformer decoder层，117million参数；最初也和BERT类似做linear probing微调
- GPT-2（2019）：1.5B参数，转换为生成式方式完成任务
- GPT-3（2020）：175B参数，更强大的zero-shot/few-shot能力
- GPT-3.5（2022年底）
- GPT-4（2023.3）

来源：Stanford CS224N

# 模型预训练

- 三种基于Transformer的预训练类型
  - Decoder（GPT系列）

- 展现出scaling laws的特性
  - 增大模型参数量能使模型的能力越来越强



# 模型预训练

## ■ 没有预训练，就没有现在的大模型

- 大模型的架构没有门槛，完全透明
  - ❖ 可以从huggingface上看到所有最强开源模型的模型参数及架构

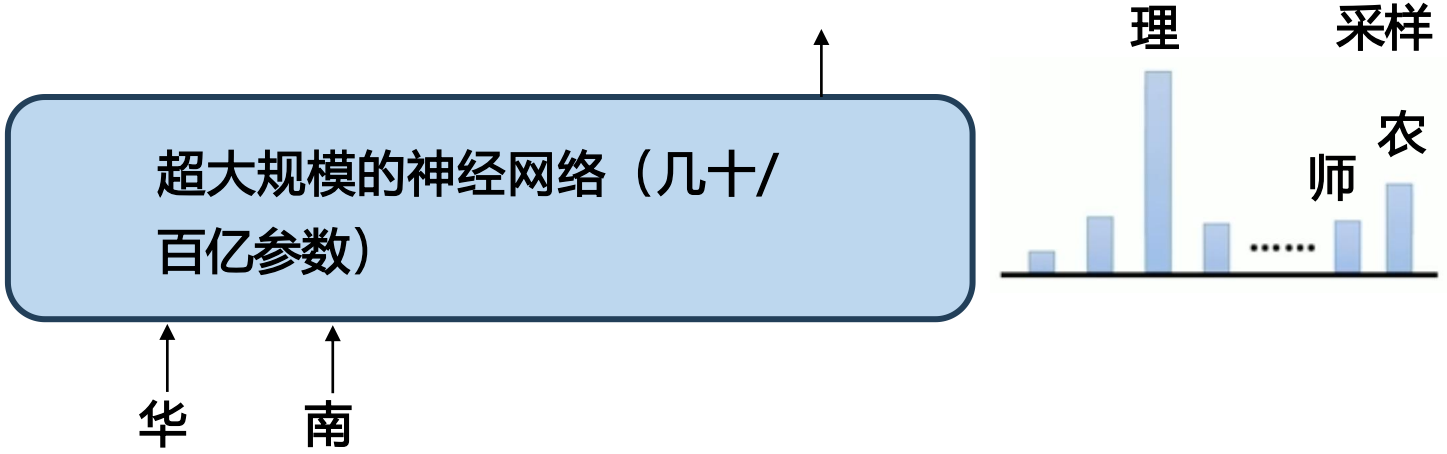
| | DeepSeek-V3.2 | DeepSeek-V4-Pro | Qwen3.8-2.4T-A95B |
|---|---|---|---|
| Total Params | 671B | 1.6T | 2.4T |
| Active Params | 37B | 49B | 95B |
| Layers | 61 | 61 | 92 |
| Hidden | 7168 | 7168 | 8192 |
| Experts | 256 | 384 | 512 |
| Top-K | 8 | 6 | 10 |
| Expert dim | 2048 | 3072 | 2048 |
| Context | 164K | 1M | 262K |
| Attention | MLA + sparse | CSA + HCA | Linear + Full |
| Main scaling strategy | MoE | larger/sparser MoE + compressed attention | huge MoE + deeper/wider backbone |

- 构建大模型更依赖于AI基础设施（包括硬件、数据等）和工程化落地实践（预训练、后训练）

# 大模型工作原理

**一句话概括**：以词元（token）形式进行接龙

怎么决定下一个token：华南 → 理、农、师 ...?




三个组成部份：

从模型Inference的角度

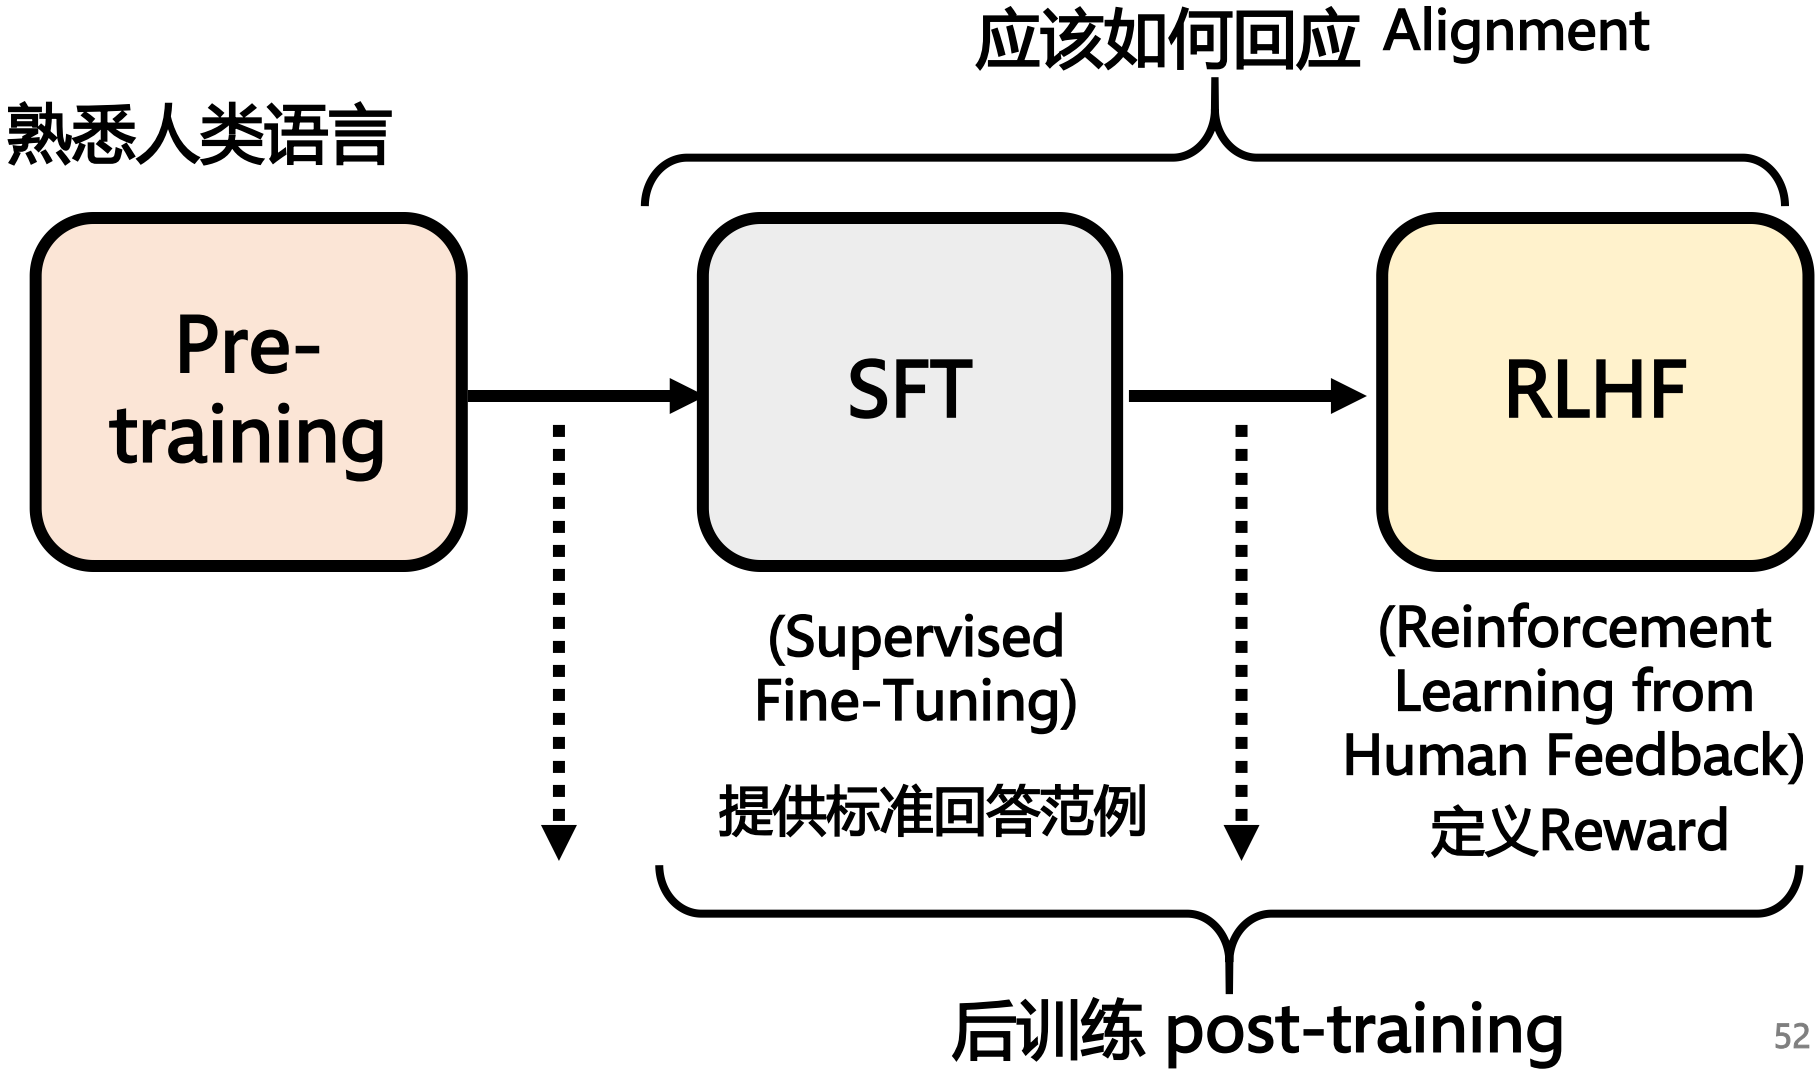
1.输入的token的划分和表示

2.模型架构

3.模型训练

# 大模型的训练

- 从模型预训练到最终的大模型，还差哪些环节？



# 模型预训练

## ■ 预训练

- 刚才已经从Transformer出发，讲述了主流Decoder架构大模型的预训练过程
  - 简而言之：做语言模型（language modeling）
  - 海量的训练资料（Deepseek V3 15T tokens）

> We present DeepSeek-V3, a strong Mixture-of-Experts (MoE) language model with 671B total parameters with 37B activated for each token. To achieve efficient inference and cost-effective training, DeepSeek-V3 adopts Multi-head Latent Attention (MLA) and DeepSeekMoE architectures, which were thoroughly validated in DeepSeek-V2. Furthermore, DeepSeek-V3 pioneers an auxiliary-loss-free strategy for load balancing and sets a multi-token prediction training objective for stronger performance. We pre-train DeepSeek-V3 on 14.8 trillion diverse and high-quality tokens, followed by Supervised Fine-Tuning and Reinforcement Learning stages to fully harness its capabilities. Comprehensive evaluations reveal that DeepSeek-V3 outperforms other open-source models and achieves performance comparable to leading closed-source models. Despite its excellent performance, DeepSeek-V3 requires only 2.788M H800 GPU hours for its full training. In addition, its training process is remarkably stable. Throughout the entire training process, we did not experience any irrecoverable loss spikes or perform any rollbacks.

  - 预训练资料是宝贵的基础设施（公司的核心资产）

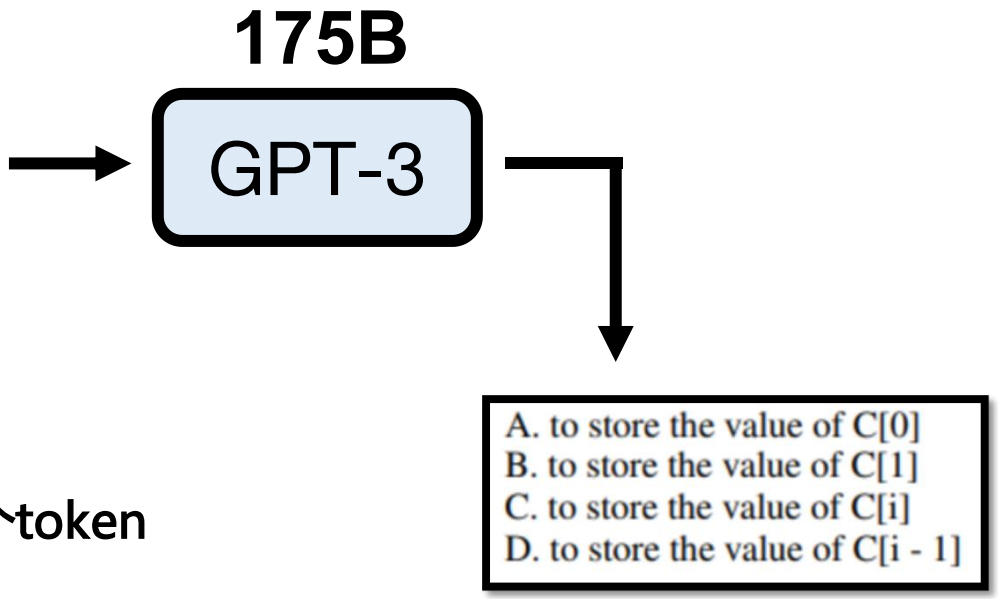
# 模型预训练

## ■ SFT

- 语言模型经常不能满足人类的意图

What is the purpose of the list C in the code below?

```
def binomial_coefficient(n, r):
    C = [0 for i in range(r + 1)];
    C[0] = 1;
    for i in range(1, n + 1):
        j = min(i, r);
        while j > 0:
            C[j] += C[j - 1];
            j -= 1;
    return C[r]
```




- 预训练只负责训练预测下一个token

来源：https://arxiv.org/abs/2203.02155

# 模型预训练

## ■ SFT

- 语言模型经常不能满足人类的意图

| | |
|---|---|
| PROMPT | *Explain the moon landing to a 6 year old in a few sentences.* |
| COMPLETION | GPT-3 |
| | `Explain the theory of gravity to a 6 year old.` |
| | `Explain the theory of relativity to a 6 year old in a few sentences.` |
| | `Explain the big bang theory to a 6 year old.` |
| | `Explain evolution to a 6 year old.` |

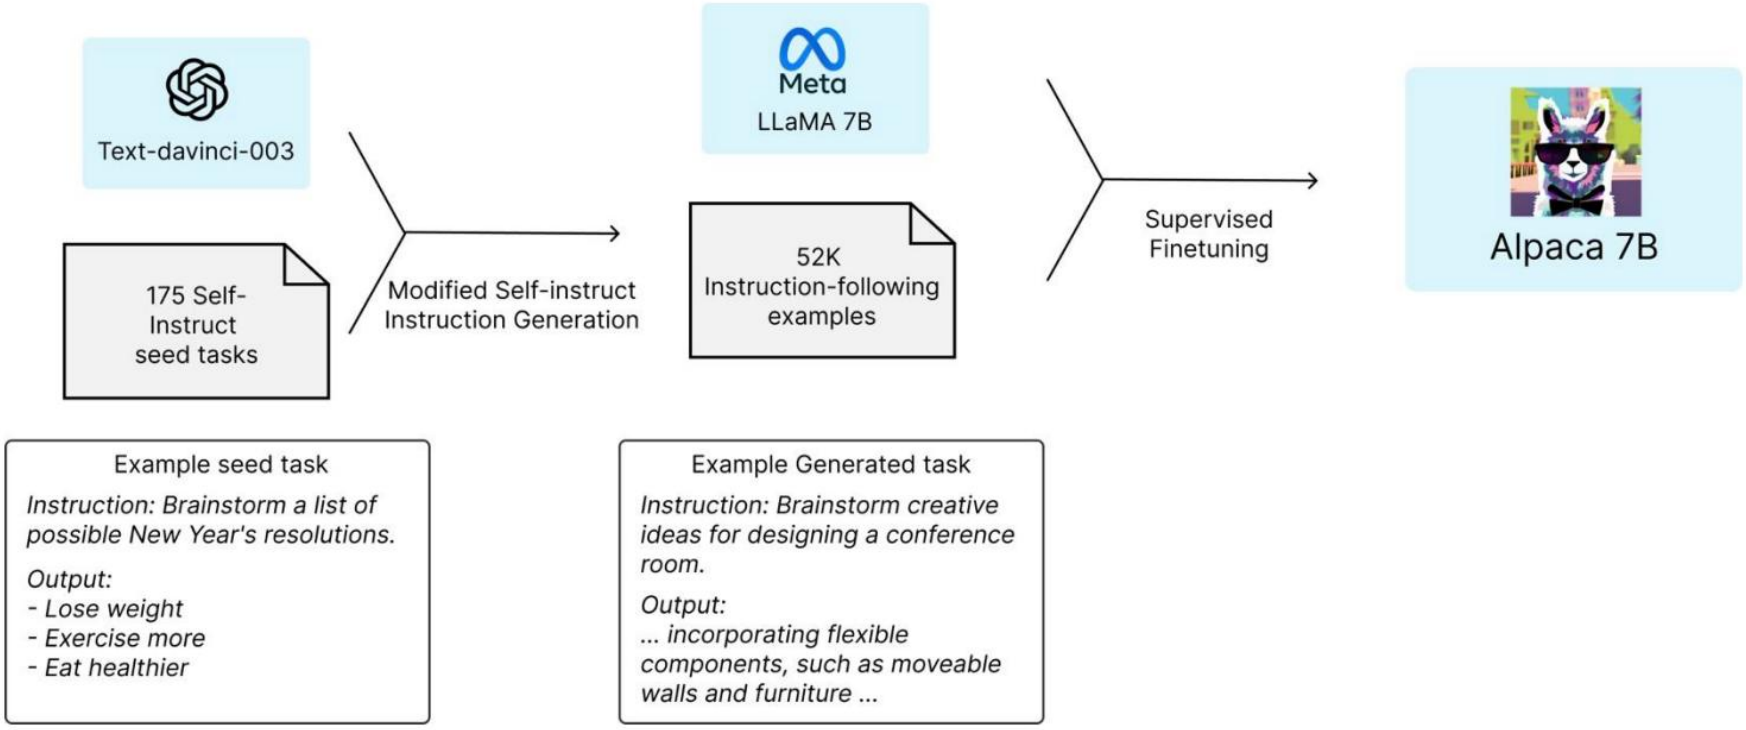
- 预训练只负责训练预测下一个token

来源：Stanford CS224N

# 模型预训练

## ■ SFT

- 微调已经在BERT和T5系列的下游任务适配中被广泛应用
  - Alpaca 7B的SFT过程：




来源：Stanford CS224N

# 模型预训练

## ■ SFT

- 微调已经在BERT和T5系列的下游任务适配中被广泛应用
  - Deepseek-R1的训练过程中包含多个步骤的SFT：

$$\text{V3-Base} \rightarrow \text{Cold-start SFT} \rightarrow \text{Reasoning RL} \rightarrow \text{Rejection Sampling} + \text{SFT} \rightarrow \text{RL}$$

  - Cold-start SFT（几千条）：
    - “fine-tuned with thousands of long Chain-of-Thought examples”
    - SFT更在意数据质量，而不是以数量取胜
  - 第二轮SFT（800K）：
    - 通过第一步RL后进行rejection sampling，得到600k与reasoning相关数据：
      - “In total, we collect about 600k reasoning related training samples.”
    - writing、factual QA，translation等任务又收集200k数据：
      - “approximately 200k training samples that are unrelated to reasoning.”

# 模型预训练

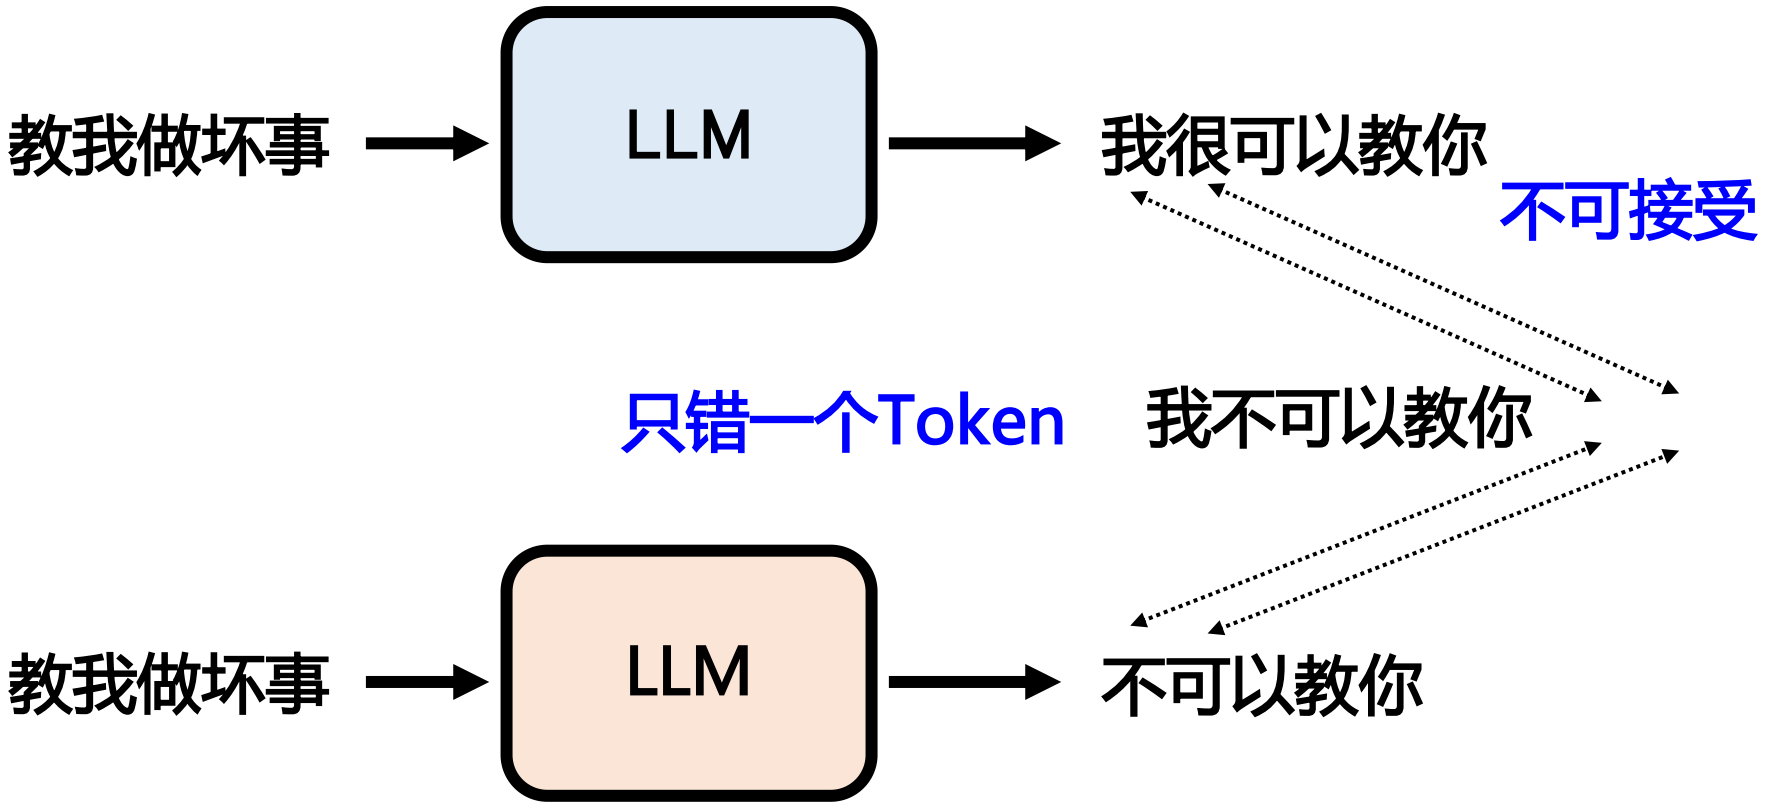
## ■ RLHF

- SFT的局限性
  - 收集质量高，对模型能力确实能提升的SFT资料代价很昂贵
  - 一些开放性的问题并没有标准答案
    - 写一个关于时间穿越的科幻故事
  - SFT的优化策略更偏好整体的输出结构，而不是结果
    - “像不像标准答案”，训练平均惩罚每一个token

# 模型预训练

## ■ RLHF

- RLHF可以用来显式对齐人类偏好
  - 不关注过程，只关注结果好还是不好



# 模型预训练

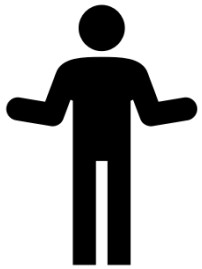
## ■ RLHF

- RLHF可以用来显式对齐人类偏好
  - 不关注过程，只关注结果好还是不好



$r_i = -1$

教我做坏事 → LLM → 我很可以教你





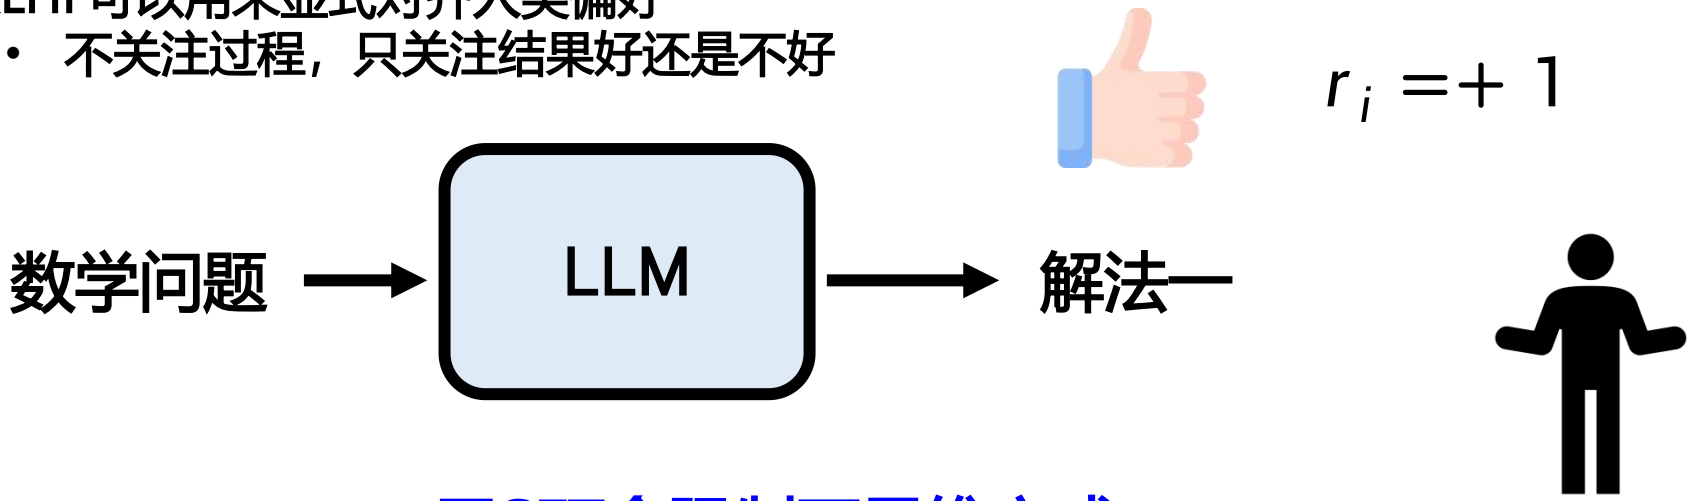
$r_i = +1$

教我做坏事 → LLM → 不可以教你

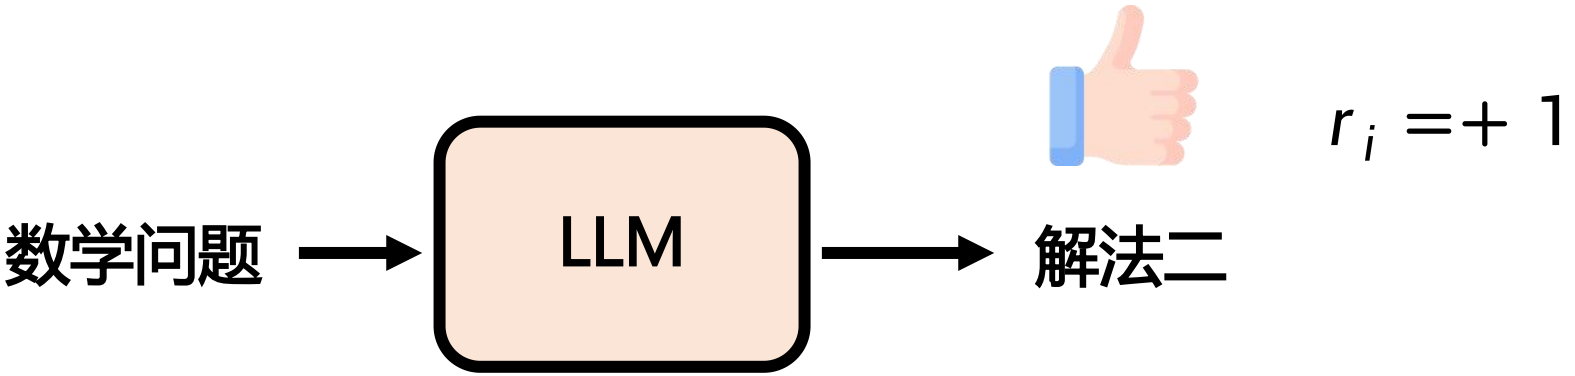
# 模型预训练

## ■ RLHF

- RLHF可以用来显式对齐人类偏好
  - 不关注过程，只关注结果好还是不好

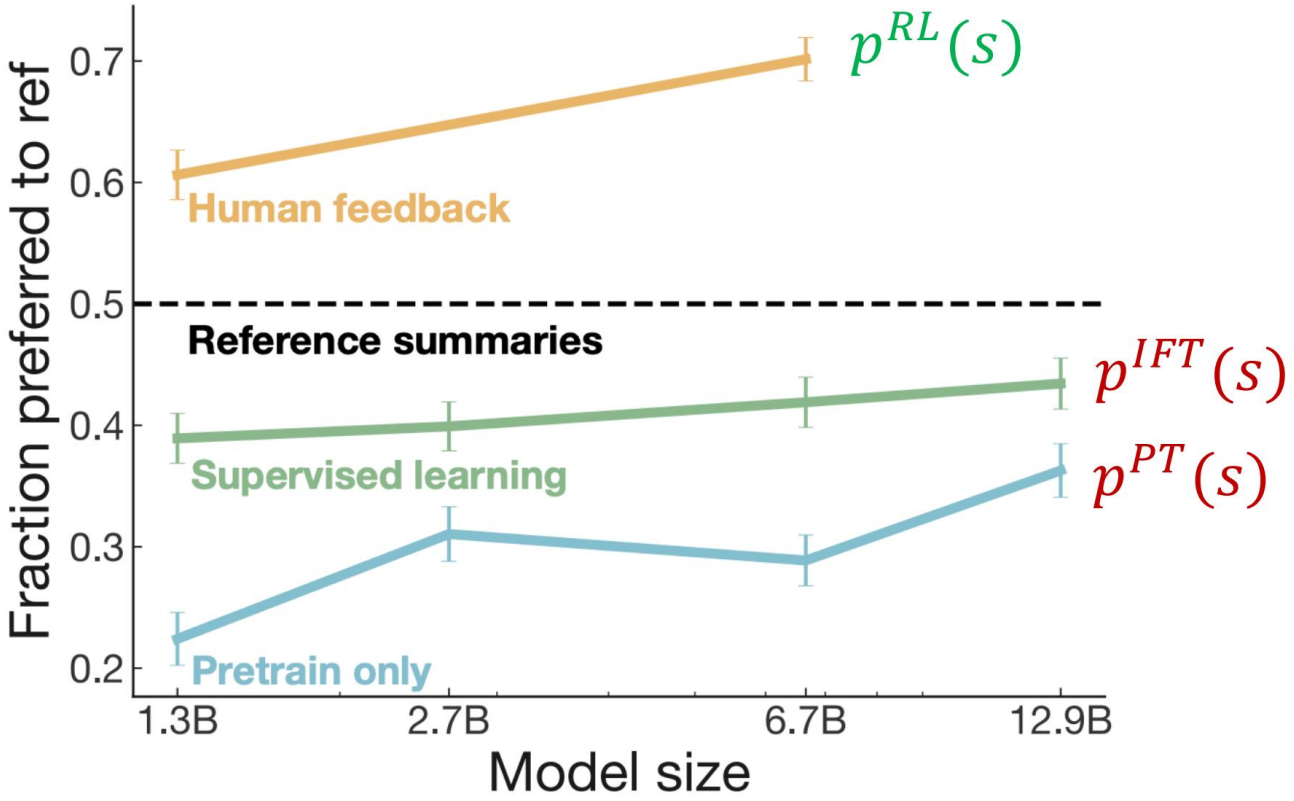



用SFT会限制死思维方式



# 模型预训练

- RLHF能在Pre-training和SFT基础上进一步提升



# 模型预训练

- ChatGPT

Step 1

**Collect demonstration data, and train a supervised policy.**

A prompt is sampled from our prompt dataset.

A labeler demonstrates the desired output behavior.

This data is used to fine-tune GPT-3 with supervised learning.



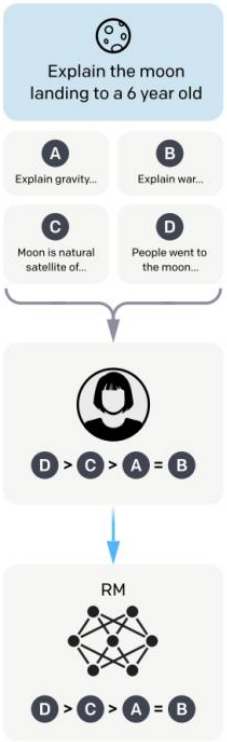

Step 2

**Collect comparison data, and train a reward model.**

A prompt and several model outputs are sampled.

A labeler ranks the outputs from best to worst.

This data is used to train our reward model.




Step 3

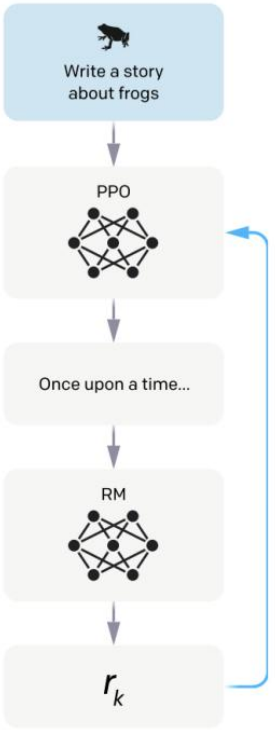
**Optimize a policy against the reward model using reinforcement learning.**

A new prompt is sampled from the dataset.

The policy generates an output.

The reward model calculates a reward for the output.

The reward is used to update the policy using PPO.



# 模型预训练

- ChatGPT

**ChatGPT: Optimizing Language Models for Dialogue**

Note: OpenAI (and similar companies) are keeping more details secret about ChatGPT training (including data, training parameters, model size)—perhaps to keep a competitive edge…

## Methods

We trained this model using Reinforcement Learning from Human Feedback (RLHF), using the same methods as InstructGPT, but with slight differences in the data collection setup. We trained an initial model using supervised fine-tuning: human AI trainers provided conversations in which they played both sides—the user and an AI assistant. We gave the trainers access to model-written suggestions to help them compose their responses. We mixed this new dialogue dataset with the InstructGPT dataset, which we transformed into a dialogue format.

**(Instruction finetuning!)**

# 模型预训练

- ChatGPT

**ChatGPT: Optimizing Language Models for Dialogue**

Note: OpenAI (and similar companies) are keeping more details secret about ChatGPT training (including data, training parameters, model size)—perhaps to keep a competitive edge…

## Methods

To create a reward model for reinforcement learning, we needed to collect comparison data, which consisted of two or more model responses ranked by quality. To collect this data, we took conversations that AI trainers had with the chatbot. We randomly selected a model-written message, sampled several alternative completions, and had AI trainers rank them. Using these reward models, we can fine-tune the model using Proximal Policy Optimization. We performed several iterations of this process.

**(RLHF!)**

# 智能体

- Agent = LLM?

> 一个以大模型为核心大脑，具备自主理解、规划、记忆和工具使用能力的计算系统。

- 现代Agent = LLM（大脑）+ 上下文（眼睛）+ 工具（手脚）

  + 约束、验证、纠正 （保障）

- 现代Agent = LLM + （上下文 + 工具 + 约束、验证、纠正）

  = Model + Harness

# Takeaways

- 大模型（生成式）定义、工作形式
- 从输入到输出的架构流程
- 预训练
- 后训练

# 课后学习

- Transformer的细节
- 模型预训练的详细发展历程
- 后训练中RL的最新发展
  - DPO、GRPO等